

APRENDIZADO NÃO SUPERVISIONADO




Prof. Dr. Anderson Ara

Slide 01

Aprendizado Não Supervisionado

Aprendizado via Dados



Aprendizado via Dados

Pode-se dizer que um programa de computador aprende a partir de uma experiência **E** com respeito a uma classe de tarefas **T** e com medida de desempenho **P**, se seu desempenho **P** na tarefa **T** melhora com a experiência **E** (Mitchell, 1997).

Aprendizado via Dados

Seja $\mathbf{X} \in \mathcal{X}$ um vetor de variáveis de entrada e $Y \in \mathcal{Y}$ uma variável de saída. Suponha que $(\mathbf{X}, Y)$ possa ser representado pela função de probabilidade conjunta

$$P(\mathbf{X}, Y) = P(Y|\mathbf{X}) P(\mathbf{X})$$

O estudo de $P(Y|\mathbf{X})$ refere-se ao **aprendizado supervisionado**, bem como o estudo de $P(\mathbf{X})$ refere-se ao **não aprendizado supervisionado**.

Aprendizado Não Supervisionado

Na aprendizagem não supervisionada não há variáveis de saída, apenas variáveis de entrada. O objetivo é descrever **associações e padrões** referentes a este conjunto.

Os métodos utilizados são direcionados ao reconhecimento de padrões nos dados, ou seja, sem distinção entre variáveis explicativas e respostas. Neste contexto, o objetivo é compreender a estrutura de associação entre as variáveis ou observações.

Note que esses padrões podem ser utilizados como novas variáveis (latentes) em problemas de aprendizado supervisionados.

ALGUMAS QUESTÕES

- ! Existe uma maneira informativa para visualizar os dados? Em especial, quando o número de variáveis $p \gg 2$.
- ! Podemos descobrir subgrupos entre as variáveis ou entre as observações?

IMPORTÂNCIA EM DIVERSAS ÁREAS

- ! Um pesquisador de câncer pode testar os níveis de expressão gênica em uma centena de pacientes com câncer de mama. Ele pode, então, procurar subgrupos entre as amostras de câncer de mama, ou entre os genes, para obter uma melhor compreensão da doença.
- ! Um mecanismo de pesquisa pode escolher quais resultados de pesquisa exibir para um indivíduo específico com base no histórico de buscas de outros indivíduos com padrões de pesquisa semelhantes.

IMPORTÂNCIA EM DIVERSAS ÁREAS

- ! Lojas procuram regras para para sugerir produtos que são frequentemente comprados conjuntamente.
- ! Um site de compras online pode tentar identificar grupos de compradores com históricos de navegação e compra semelhantes, bem como itens que são de particular interesse para os compradores dentro de cada grupo. Em seguida, a um cliente individual, pode ser mostrado, preferencialmente, os itens em que ele é susceptível de estar interessado, com base nos históricos de compra de compradores semelhantes

TÉCNICAS COMUNS DESTE TIPO DE APRENDIZADO

- ! Estimac o de densidade
- ! An lise de agrupamentos (clustering)
- ! T cnicas de redu o de dimensionalidade
- ! Regras de associa o
- ! Detec o de anomalia

TÉCNICAS COMUNS DESTE TIPO DE APRENDIZADO:

Estimação de densidade: refere-se a construção de uma estimativa, com base em dados observados, de uma função de densidade de probabilidade subjacente não observável.

Análise de agrupamentos (clustering): procura encontrar subgrupos homogêneos entre as observações de um conjunto de dados.

Técnicas de redução de dimensionalidade: procura encontrar uma representação de baixa dimensão das observações, pode explicar de alguma forma o relacionamento de variáveis ou observações.

Regras de associação: busca encontrar padrões e conexões em dados. É uma técnica que pode ser utilizada para descobrir regras que explicam como itens são relacionados.

Detecção de Anomalias procura identificar padrões incomuns ou desvios significativos nos dados que diferem do comportamento esperado. Esses outliers podem indicar falhas, fraudes, erros ou eventos raros.

ESTATÍSTICA E CIÊNCIA DE DADOS

Estatística:

- Guia a coleta e análise de dados complexos.

Computação

- Desenvolve algoritmos para processar grandes volumes de dados.
- Distribui dados entre múltiplos processadores e otimiza armazenamento.

Humana

- Aplica modelos estatísticos e computacionais para resolver problemas específicos.
- Decide quais dados obter, processar e visualizar.
- Comunica resultados de forma clara e acessível.

Blei, D. M., & Smyth, P. (2017). Science and data science. Proceedings of the National Academy of Sciences, 114(33), 8689-8692.

APRENDIZADO NÃO SUPERVISIONADO E ESTATÍSTICA MULTIVARIADA

Os métodos de aprendizado não supervisionado utilizam técnicas da **Estatística Multivariada** para encontrar padrões, estruturas ou agrupamentos nos dados sem a necessidade de rótulos pré-definidos.

Nota-se que estes métodos são essencialmente **descritivos**.