

APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 02

Estimação de Densidade

ESTATÍSTICA NÃO PARAMÉTRICA

A estatística não paramétrica refere-se a uma coleção de métodos estatísticos nos quais os dados **não são assumidos** como provenientes de modelos prescritos, determinados por um número de parâmetros.

Alguns exemplos de métodos paramétricos: o modelo de distribuição normal e o modelo de regressão linear.

ESTIMAÇÃO DE DENSIDADE

Considere uma variável aleatória X com função densidade de probabilidade $f_X(x)$. A probabilidade de $X \in [-h/2, h/2]$ é:

$$P(X \in [-h/2, h/2]) = \int_{-h/2}^{h/2} f_X(x) dx.$$

Uma estimativa da densidade f pode ser pensada como contar o número de observações que pertencem a cada intervalo e dividi-lo pelo número total de observações.

Estimação de Densidades

- Em outras palavras, dado um conjunto de observações, $x_1, \dots, x_n$, temos:

$$P(X \in [-h/2, h/2]) \approx \frac{1}{n} \#\{x_i \in [-h/2, h/2]\}.$$

Ou seja,

$$P(X \in [-h/2, h/2]) = \int_{-h/2}^{h/2} f_X(x) dx \approx f(\xi)h,$$

com $\xi \in [-h/2, h/2]$. Assim, uma estimativa para f seria:

$$\hat{f}_h(x) = \frac{1}{nh} \#\{x_i \in [-h/2, h/2]\},$$

para todo $x \in x_i \in [-h/2, h/2]$.

Estimação de Densidades

- Formalmente, suponha uma amostra aleatória $X_1, \dots, X_n$ da variável aleatória X com f desconhecida e observamos $x_1, \dots, x_n$.
- Seja k o número de intervalos de comprimento h e defina C_j por:

$$C_j = [x_0 + (j-1)h, x_0 + jh], \quad j = 1, 2, \dots, k.$$

- Seja $n_j = \sum_{i=1}^n I(x_i \in C_j)$, tal que $n = \sum_{j=1}^k n_j$.

- Então, $\hat{f}_h(x) = \frac{1}{nh} \sum_{j=1}^k n_j I(x \in C_j)$.

Estimação de Densidades

Observações:

1 - É fácil ver que a estimativa de $\hat{f}_h(x)$ depende fortemente da escolha de h (consequentemente, de k).

2 - h é chamado de parâmetro de suavização.

`hist(x, nclass=, prob=T)`

Generalização

A ideia e motivação do histograma sugere, naturalmente, uma generalização considerando funções do tipo:

$$K(x) = \begin{cases} \frac{1}{2}, & \text{se } |x| < 1 \\ 0, & \text{caso contrário.} \end{cases}$$

- Estimação pelo método Kernel ou funções de kernel
- KDE: kernel density estimation

Método Kernel

- Consequentemente, pode-se sugerir uma nova estimativa para f como sendo:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K \left(\frac{x - x_i}{h} \right).$$


- Esta nova estimativa generaliza aquela baseada no Histograma.
- Este estimador 'ingênuo' tem a característica de não suavidade.
- Para superar o fato de não suavidade, faz-se suposições bastantes razoáveis sobre a função kernel K . Por exemplo K pode ser uma Gaussiana.

Método Kernel

Alguns exemplos de função kernel:

Tipos	Funções
Retangular	$\begin{cases} \frac{1}{2}, & x < 1 \\ 0, & \text{caso contrário} \end{cases}$
Triangular	$\begin{cases} 1 - x , & x < 1 \\ 0, & \text{caso contrário} \end{cases}$
Gaussiano	$\frac{1}{\sqrt{2\pi}} e^{-x^2/2}$


Método Kernel



<https://scikit-learn.org/>

Cuidado com o termo **kernel**. Sua tradução literal é *núcleo* e ele pode estar presente em diversos contextos. Alguns kernels acima não satisfazem a condição de ser uma função de kernels positiva definida (Teorema de Mercer) e não são utilizados em outras na teoria de SVM.

Método Kernel



Método Kernel

- A estimativa é fortemente influenciada pela escolha de h .
- Quanto menor for o tamanho de h menos suave será a estimativa (mais ruído).
- De maneira oposta, quanto maior for o h mais suave será a estimativa final.

Método Kernel

Parâmetro de Suavização

A Escolha do Parâmetro de Suavização

- a. Existem várias maneiras para se fazer uma boa escolha de h .
- b. As comumente utilizadas são:
 - A regra prática de Silverman (1986).
 - Validação cruzada por máxima verossimilhança.

Método Kernel

Parâmetro de Suavização

Para a regra prática de Silverman:


$$\begin{aligned}\hat{h} &= 1,06 \min \left(\hat{\sigma}, \frac{Q_3 - Q_1}{\Phi(3/4) - \Phi(1/4)} \right) \\ &= 1,06 \min \left(\hat{\sigma}, \frac{Q_3 - Q_1}{1,349} \right)\end{aligned}$$

em que Φ é a densidade de uma normal padrão.



Método Kernel

```
x=iris$Sepal.Length  
hist(x,prob=T,col="gray",main="",border="white")  
lines(density(x), col = "red", lwd = "2")  
lines(density(x,bw=1), col = "blue", lwd = 2)  
lines(density(x,kernel="rectangular"), col = "gold", lwd = 2)
```


Método Kernel



Método Kernel Multivariado



<https://towardsdatascience.com/>

- DESAFIO 1