

APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 03

Análise de Correspondência: primeiros passos

Análise de Correspondência

Análise de Correspondência (CA) foi proposta por Herrmann (Hirschfeld) Hartley (1935) e posteriormente desenvolvido por Jean-Paul Benzécri (1973).

A CA decompõe as estatísticas qui-quadrado associadas à tabela de dados em dois conjuntos de componentes ortogonais que descrevem, respectivamente, o padrão de associações entre os elementos das linhas e entre os elementos das colunas da tabela de dados.

Análise de Correspondência


- Técnica para exibir graficamente uma tabela de contingência.
- Baseia-se na decomposição do qui-quadrado da tabela.
- Similar à Análise de Componentes Principais para dados categóricos.

Tabela de Contingência

Considere um questionário aplicado a alunos do ensino médio. O questionário contém 8 questões de "sim" ou "não", onde os alunos podiam escolher quais responder.

Questão	Sim	Não	Total
Q1	155	938	1093
Q2	19	63	82
Q3	395	542	937
Q4	61	64	125
Q5	1336	876	2212
Q6	22	14	36
Q7	864	354	1218
Q8	920	185	1105
Total	3772	3036	6808

Gráfico Mosaico




Perfis das Linhas

A tabela abaixo exibe os perfis de resposta (em %) para cada questão:

Questão	Sim (%)	Não (%)	Total (%)
Q1	14.18	85.82	100.00
Q2	23.17	76.83	100.00
Q3	42.16	57.84	100.00
Q4	48.80	51.20	100.00
Q5	60.40	39.60	100.00
Q6	61.11	38.89	100.00
Q7	70.94	29.06	100.00
Q8	83.26	16.74	100.00
Total	55.41	44.59	100.00


Gráfico de Dispersão



Análise dos Resultados

- A questão Q1 teve a menor taxa de respostas "sim" (14.18%).
- A questão Q8 teve a maior taxa de respostas "sim" (83.26%).
- O padrão geral indica um aumento na aceitação das questões ao longo da pesquisa.

Mapa de Correspondência



As representações gráfica anteriores

- Gráficos de perfis das linhas mostram a variação das respostas ao longo das questões.
- Um gráfico de dispersão pode ser usado para visualizar padrões nas respostas.
- O **mapa de correspondência** representa graficamente as relações entre categorias. Se a pesquisa fosse composta de perguntas de múltipla escolha, cada uma com três respostas possíveis, o gráfico anterior seria tridimensional.

Decomposição em Valores Singulares

A **Decomposição em Valores Singulares** (SVD - Singular Value Decomposition) é uma técnica fundamental em álgebra linear com aplicações em compressão de dados, processamento de imagens, redução de dimensionalidade e aprendizado de máquina.

O **SVD** permite fatorar uma matriz real ou complexa em três matrizes de propriedades bem definidas.

Essencial para diversas aplicações na estatística, ciência de dados e aprendizado de máquina.

SVD: Definição Matemática

Seja $\mathbf{A}$ uma matriz real de dimensão $m \times n$, então sua decomposição em valores singulares é dada por:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$

onde:

- $\mathbf{U}$ é uma matriz ortogonal $m \times m$ cujas colunas são os autovetores de $\mathbf{A}\mathbf{A}^T$.
- $\mathbf{\Sigma}$ é uma matriz diagonal $m \times n$ contendo os valores singulares σ_i de $\mathbf{A}$, que são as raízes quadradas dos autovalores de $\mathbf{A}^T\mathbf{A}$ ou $\mathbf{A}\mathbf{A}^T$.
- $\mathbf{V}$ é uma matriz ortogonal $n \times n$ cujas colunas são os autovetores de $\mathbf{A}^T\mathbf{A}$.

SVD: Definição Matemática

A matriz Σ tem a seguinte forma:


$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_r \\ 0 & 0 & \dots & 0 \end{bmatrix}$$

onde os valores σ_i são os valores singulares, ordenados de forma decrescente $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$.

SVD: Interpretação Geométrica

- A matriz **A** transforma um espaço vetorial original em um novo espaço.
- **V** executa uma rotação para uma base onde a transformação é simplificada.
- Σ escala cada direção por um fator σ_i .
- **U** aplica uma nova rotação no espaço transformado.

SVD: Interpretação Geométrica



Strang (1993)

Decomposição em Valores Singulares

Seja $\mathbf{A}$ uma matriz real de dimensão $m \times n$. Note que $\mathbf{U}$ e $\mathbf{V}$ são matrizes ortonormais ($\mathbf{U}\mathbf{U}^T = \mathbf{V}^T\mathbf{V} = \mathbf{I}$):

$$\mathbf{A}\mathbf{V} = \mathbf{U}\Sigma$$

$$\implies \mathbf{A}\mathbf{V}\mathbf{V}^{-1} = \mathbf{U}\Sigma\mathbf{V}^{-1}$$

$$\implies \mathbf{A}\mathbf{I} = \mathbf{U}\Sigma\mathbf{V}^T$$

$$\implies \mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$$

Decomposição em Valores Singulares

Se $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$, então:

$$\begin{aligned}\mathbf{A}^T\mathbf{A} &= (\mathbf{U}\Sigma\mathbf{V}^T)^T(\mathbf{U}\Sigma\mathbf{V}^T) \\ &= \mathbf{V}\Sigma\mathbf{U}^T\mathbf{U}\Sigma\mathbf{V}^T \\ &= \mathbf{V}\Sigma^2\mathbf{V}^T\end{aligned}$$

$$\begin{aligned}\mathbf{A}^T\mathbf{A}\mathbf{V} &= \mathbf{V}\Sigma^2\mathbf{V}^T\mathbf{V} \\ &= \mathbf{V}\Sigma^2\end{aligned}$$

O mesmo pode ser verificado para $\mathbf{A}\mathbf{A}^T$.

Note que este é o mesmo problema referente a decomposição em autovalores e autovetores.

Autovetores e Autovalores

A decomposição em valores singulares e a decomposição em autovalores são intimamente relacionadas.

Um **vetor (não nulo)** $\mathbf{v}$ de dimensão p é um **autovetor** de uma matriz quadrada $p \times p$ $\mathbf{A}$ se ele satisfaz a equação linear:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

para algum escalar λ . Esse escalar λ é chamado de **autovalor** correspondente a $\mathbf{v}$.

Geometricamente, os autovetores de $\mathbf{A}$ são os vetores que **são apenas esticados ou encolhidos** por $\mathbf{A}$, sem mudança de direção. O fator pelo qual eles são alongados ou reduzidos é dado pelo autovalor λ .

A equação acima é conhecida como **equação do autovalor** ou **problema do autovalor**.

Autovetores e Autovalores

```
A <- matrix(c(4, 1, 1, 3), nrow = 2, byrow = TRUE)

# Autovalores e autovetores
eig <- eigen(A)

# Extraíndo autovalores e autovetores
V <- eig$vectors
D <- diag(eig$values)

# Verificando a relação  $AV = DV$ 
AV <- A %*% V
DV <- V %*% D
```

Autovetores e Autovalores

```
# Comparando os resultados  
AV
```

```
##           [,1]      [,2]  
## [1,] -3.928334  1.252274  
## [2,] -2.427844 -2.026221
```

```
DV
```

```
##           [,1]      [,2]  
## [1,] -3.928334  1.252274  
## [2,] -2.427844 -2.026221
```

SVD: Algumas Propriedades

1. O número de valores singulares diferentes de zero de $\mathbf{A}$ é igual ao seu posto.
2. A decomposição SVD pode ser usada para calcular a pseudo-inversa de Moore-Penrose:

$$\mathbf{A}^+ = \mathbf{V}\Sigma^+\mathbf{U}^T$$

onde Σ^+ é a inversa da matriz Σ para os valores singulares não nulos.

3. É a melhor aproximação de posto reduzido para $\mathbf{A}$ segundo a norma de Frobenius, usada na redução de dimensionalidade.

SVD: Exemplo Numérico

Seja a matriz:

$$\mathbf{A} = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix}$$

Aplicando SVD, obtemos:

$$\mathbf{U} = \begin{bmatrix} 0.707 & 0.707 \\ 0.707 & -0.707 \end{bmatrix}, \Sigma = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 3 & 0 \end{bmatrix}, \mathbf{V}^T = \begin{bmatrix} 0.707 & 0.707 & 0 \\ 0.263 & -0.263 & 0.943 \\ 0.667 & -0.667 & -0.333 \end{bmatrix}$$

Assim, a matriz $\mathbf{A}$ pode ser reconstruída como:

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$$

SVD: Exemplo Numérico

```
A=matrix(c(3,2,2,  
          2,3,-2),  
        nrow=2,byrow=T)
```

A

```
##      [,1] [,2] [,3]  
## [1,]    3    2    2  
## [2,]    2    3   -2
```


SVD: Exemplo Numérico

```
# Decomposição SVD via função svd
svd_decomp <- svd(A)

A1 <- svd_decomp$u*%diag(svd_decomp$d)*%t(svd_decomp$v)
```

A1

```
##      [,1] [,2] [,3]
## [1,]    3    2    2
## [2,]    2    3   -2
```

SVD: Exemplo Numérico

```
# Decomposição via AA' e A'A
AAt <- A %*% t(A)
AtA <- t(A) %*% A

# AAt
eigen_AAt <- eigen(AAt, symmetric = TRUE)
UU <- eigen_AAt$vectors
dd <- eigen_AAt$values

# AtA
eigen_AtA <- eigen(AtA, symmetric = TRUE)
VV <- eigen_AtA$vectors

DD <- matrix(0, nrow = nrow(UU), ncol = ncol(VV))
dim_D <- min(length(dd), nrow(DD), ncol(DD))
diag(DD)[1:dim_D] <- sqrt(dd)

A2 <- UU[2:1,] %*% DD %*% t(VV)
```

SVD: Exemplo Numérico

#Verificando

A

```
##      [,1] [,2] [,3]
## [1,]    3    2    2
## [2,]    2    3   -2
```

A1

```
##      [,1] [,2] [,3]
## [1,]    3    2    2
## [2,]    2    3   -2
```

A2

```
##      [,1] [,2] [,3]
## [1,]    3    2    2
## [2,]    2    3   -2
```

Análise de Correspondência

A Análise de Correspondência (AC) é uma técnica estatística utilizada para explorar e visualizar a associação entre categorias de variáveis qualitativas. No contexto da criminologia, a AC permite identificar padrões e relações entre diferentes tipos de crimes e suas características associadas.

Utilizará a **SVD** para decompor as **estatísticas qui-quadrado** associadas à tabela de dados em dois conjuntos de componentes ortogonais que descrevem, respectivamente, o padrão de associações entre os elementos das linhas e entre os elementos das colunas da tabela de dados.

A AC baseia-se na decomposição da matriz de contingência permitindo uma representação geométrica das associações entre linhas e colunas. Essa abordagem facilita a interpretação das relações subjacentes aos dados categóricos.

Análise de Correspondência

Seja uma matriz de contingência de dimensão $I \times J$, onde I e J representam o número de categorias das variáveis estudadas, dada por:

VarA \ VarB	Cat. 1	Cat. 2	...	Cat. J	Total
Cat. 1	n_{11}	n_{12}	...	n_{1J}	$n_{1.}$
Cat. 2	n_{21}	n_{22}	...	n_{2J}	$n_{2.}$
...	...	...	...	...	...
Cat. I	n_{I1}	n_{I2}	...	n_{IJ}	$n_{I.}$
Total	$n_{.1}$	$n_{.2}$	...	$n_{.J}$	$n = n_{..}$

Análise de Correspondência

Definimos a matriz de proporções como

$$\mathbf{P} = \left[\frac{n_{ij}}{n} \right], \quad \text{com } i = 1, \dots, I \text{ e } j = 1, \dots, J$$

definimos os totais marginais das linhas e colunas:

$$r_i = \sum_{j=1}^J p_{ij}, \quad c_j = \sum_{i=1}^I p_{ij}$$

o mesmo que

$$\mathbf{r} = \mathbf{P}\mathbf{1}, \quad \mathbf{c} = \mathbf{P}^T\mathbf{1}$$

Análise de Correspondência

Normalização das margens:

$$\mathbf{D}_r = [\text{diag}(\mathbf{r})], \quad \mathbf{D}_c = [\text{diag}(\mathbf{c})]$$

A Análise de Correspondência consiste em decompor a matriz de resíduos centrada e ponderada:

$$\mathbf{S} = \mathbf{D}_r^{-1/2}(\mathbf{P} - \mathbf{r}\mathbf{c}^T)\mathbf{D}_c^{-1/2}$$

por meio de uma decomposição em valores singulares (SVD), de modo que:

$$\mathbf{S} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$

onde $\mathbf{U}$ e $\mathbf{V}$ são matrizes ortogonais e $\mathbf{\Sigma}$ contém os valores singulares.

Análise de Correspondência

As coordenadas fatoriais das linhas e colunas são obtidas por:

$$\mathbf{F} = \mathbf{D}_r^{-1/2} \mathbf{U} \Sigma$$

$$\mathbf{G} = \mathbf{D}_c^{-1/2} \mathbf{V} \Sigma$$

Essas coordenadas são utilizadas para projetar os pontos no espaço bidimensional, permitindo uma interpretação visual das associações.

Análise de Correspondência

Utilizando o fato que $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k > 0$ são os valores singulares de **S**, é possível definir a inércia total (IT) por:

$$IT = \sum_{i=1}^k \lambda_i^2$$

que indica a variabilidade dos dados no espaço determinada pelas novas coordenadas após a transformação. Da mesma forma, a inércia relativa (variância explicada) da i -ésima coordenada em relação à inércia total é

$$\frac{\lambda_i^2}{\sum_{i=1}^k \lambda_i^2}$$

a qual permite avaliar a quantidade de informação contida em cada uma das dimensões extraídas na análise.

Resultados Numéricos

- Os perfis de linha e coluna podem ser representados numa dimensão menor, $(J - 1)$ e $(I - 1)$ para representar os perfis linha e coluna, respectivamente. Como resultado, o número de dimensões que melhor expliquem a variabilidade dos dados é dada por $k = \min\{I - 1, J - 1\}$.
- Valores singulares (eigenvalues) mostram variabilidade explicada.
- Percentuais acumulados indicam adequação da redução de dimensão.
- Coordenadas fatoriais permitem a visualização bidimensional.

Algumas observações

- O procedimento básico da AC é representar tanto as categorias de linha, quanto de colunas em um mesmo gráfico, i.e., faz-se necessário representar os perfis de linha e coluna em um mesmo espaço multidimensional.
- Distância entre pontos representa similaridade dos perfis.
- Pontos próximos indicam padrões de resposta semelhantes.
- Pontos extremos indicam características distintas nas categorias.
- CA é útil para explorar relações entre categorias de dados.
- Requer cuidado na interpretação dos mapas de correspondência.
- A versão aqui apresentada é conhecida como **análise de correspondência simples**

AC no software R

```
require(FactoMineR)
require(factoextra)

# Dados fornecidos
dados <- matrix(c(155 , 938, 19, 63, 395, 542, 61, 64,
                  1336, 876, 22, 14, 864, 354, 920, 185),
                nrow = 8, byrow = TRUE)

# Adicionar os nomes das linhas e colunas
colnames(dados) <- c("Sim", "Nao")
rownames(dados) <- c("Q1", "Q2", "Q3", "Q4", "Q5", "Q6", "Q7", "Q8")
```


```
# Visualizar a tabela de contingência  
dados
```

```
##      Sim Nao  
## Q1  155 938  
## Q2   19  63  
## Q3  395 542  
## Q4   61  64  
## Q5 1336 876  
## Q6   22  14  
## Q7  864 354  
## Q8  920 185
```


```
# Realizando a análise de correspondência simples  
acm <- CA(dados, graph = FALSE)  
  
acm$eig
```

```
##          eigenvalue percentage of variance cumulative percentage of variance  
## dim 1    0.1973677                100                100
```

```
plot(acm$row$coord,pch=NA)  
text(1:8,acm$row$coord,names(acm$row$coord),col="gold",cex=1.5)
```



```
stripchart(acm$row$coord,pch=NA)  
text(acm$row$coord, 1, names(acm$row$coord),col="#5d4037", cex=1.5)  
text(acm$col$coord, 1, rownames(acm$col$coord), col="gold", cex=1.5)
```




```
### via SVD

PP=dados/sum(dados)

rr <- PP%%matrix(1,ncol=1,nrow=2)
cc <- t(PP)%%matrix(1,ncol=1,nrow=8)

Dc <- diag(c(cc)^-0.5)
Dr <- diag(c(rr)^-0.5)

S <- Dr%%(PP-rr%%t(cc))%%Dc

svd_decomp <- svd(S)

FF <- Dc%%svd_decomp$v%%svd(S)$d
GG <- Dr%%svd_decomp$u%%svd(S)$d
```

```
stripchart(GG,pch=NA)  
text(GG, 1, names(acm$row$coord),col="#5d4037", cex=1.5)  
text(FF, 1,rownames(acm$col$coord),col="gold", cex=1.5)
```

