

APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 04

Análise de Correspondência e MCA

Análise de Correspondência

Usualmente, uma análise de correspondência inclui a "melhor" representação bidimensional dos dados, juntamente com as coordenadas dos pontos plotados e uma medida (chamada inércia) da quantidade de informação retida em cada dimensão.

Inércia

A inércia total é uma medida da variação nos dados de contagem (variância total) e é definida como a soma ponderada dos quadrados:

$$\text{tr} \left[\mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}') \mathbf{D}_c^{-1/2} (\mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}') \mathbf{D}_c^{-1/2})' \right] = \sum_i \sum_j \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} = \sum_{k=1}^{J-1} \lambda_k^2$$

onde λ_k são os valores singulares obtidos a partir da decomposição em valores singulares de $\mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r}\mathbf{c}') \mathbf{D}_c^{-1/2}$.

A inércia associada à melhor aproximação reduzida de ordem $K < J$ da matriz centrada $\mathbf{P} - \mathbf{r}\mathbf{c}'$ (a solução K -dimensional) tem inércia

$$\sum_{k=1}^K \lambda_k^2.$$

Inércia

A inércia residual (variação residual) que não é explicada pela solução de posto K é igual à soma dos quadrados dos valores singulares restantes: $\lambda_{K+1}^2 + \lambda_{K+2}^2 + \cdots + \lambda_{J-1}^2$.

Para gráficos, a inércia associada à dimensão k , λ_k^2 , é normalmente exibida ao longo do eixo de coordenadas k .

Inércia Total e Qui-Quadrado

A inércia total está relacionada à medida qui-quadrado de associação em uma tabela de contingência bidimensional,

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Aqui, $O_{ij} = x_{ij}$ é a frequência observada e E_{ij} é a frequência esperada para a célula ij . No nosso contexto, se a variável da linha for independente (ou não relacionada) à variável da coluna, temos $E_{ij} = nr_i c_j$, e

$$\text{Inércia total} = \frac{1}{n} \sum_{i,j} \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} = \frac{\chi^2}{n}.$$

Coordenadas

As **coordenadas** são os valores numéricos que representam a posição de cada ponto (linha ou coluna) em um espaço de dimensões reduzidas.

- A escolha do número de dimensões é feita pelo usuário.
- Se escolhermos apenas **uma dimensão**, cada ponto terá um único valor de coordenada.
- A interpretação dessas coordenadas depende do tipo de padronização utilizada na análise.

Exemplo: Se estivermos analisando categorias de consumidores em relação às preferências de um produto, cada categoria terá uma coordenada indicando sua posição nesse espaço reduzido.

Massa

A **massa** representa o peso ou a importância relativa de cada linha (ou coluna) na tabela de contingência.

- No caso das linhas, a **massa** é simplesmente o total da linha na tabela de frequências relativas.
- Se escolhermos a padronização baseada nos **perfis de linha**, as coordenadas são calculadas a partir dessa matriz de perfis (ou seja, a matriz de probabilidades condicionais).

Analogia: Pense na massa como a importância relativa de cada grupo na análise. Se um grupo de clientes representa 50% do total de observações, ele terá mais influência nos resultados do que um grupo que representa apenas 5%.

Qualidade da Representação

A **qualidade** de um ponto indica o quão bem ele está representado no espaço de dimensões reduzidas escolhido.

- Se **todas as dimensões** forem usadas, a distância entre os pontos será exatamente preservada.
- Como normalmente usamos **menos dimensões**, parte da informação pode ser perdida.
- A **qualidade** é uma medida que indica quanto dessa informação foi mantida.

Exemplo:

- Se a **qualidade** de um ponto for **0.9 (ou 90%)**, significa que ele está muito bem representado na nova configuração.
- Se for **0.1 (ou 10%)**, significa que a posição desse ponto no espaço reduzido não explica bem sua relação com os demais pontos.

OBS: Se a qualidade for baixa, pode ser necessário aumentar o número de dimensões para obter uma melhor representação dos dados.

Inércia Relativa

A inércia total na Análise de Correspondência está relacionada ao estatístico qui-quadrado e representa a variabilidade dos dados.

A inércia relativa indica quanto um determinado ponto contribui para a inércia total, independentemente do número de dimensões escolhidas.

- Um ponto pode ter **alta qualidade** (ou seja, estar bem representado no espaço reduzido), mas contribuir pouco para a inércia total.
- Isso acontece quando um ponto tem um **padrão de distribuição semelhante à média**, ou seja, não se destaca na análise.

Exemplo:

- Se um grupo de consumidores tem preferências **muito diferentes da média**, ele terá uma **inércia relativa alta**.
- Se outro grupo tem um padrão **muito parecido com a média**, ele terá **baixa inércia relativa**, pois não contribui muito para a variabilidade dos dados.

Inércia Relativa por Dimensão

Cada ponto contribui de forma diferente para cada **dimensão** extraída na análise.

- A **inércia relativa por dimensão** indica quanto um ponto contribui para a variabilidade explicada por uma dimensão específica.
- Isso permite identificar **quais pontos são mais relevantes para cada dimensão da análise**.

Exemplo:

- Se estamos analisando perfis de clientes e temos duas dimensões:
 - **Dimensão 1** pode representar uma separação entre "Jovens" e "Idosos".
 - **Dimensão 2** pode representar uma separação entre "Clientes que gastam pouco" e "Clientes que gastam muito".
 - Cada grupo de clientes terá uma inércia relativa diferente em cada dimensão.

Coseno² (Qualidade por Dimensão)

O Coseno² (ou qualidade por dimensão) indica a correlação de um ponto com cada dimensão da análise.

- Ele representa a fração da variação de um ponto explicada por cada dimensão.
- A soma dos valores do Coseno² em todas as dimensões é igual à qualidade total do ponto.

Interpretação geométrica:

- O Coseno² é o quadrado do cosseno do ângulo entre um ponto e uma dimensão específica.
- Quanto maior esse valor, mais forte é a relação entre o ponto e aquela dimensão.

Exemplo:

- Se um ponto tem um Coseno² alto na Dimensão 1, significa que essa dimensão explica bem sua variação.
- Se o Coseno² for baixo para todas as dimensões, significa que o ponto não está bem representado no espaço reduzido.

Análise de Correspondência Múltipla

A Análise de Correspondência Múltipla (MCA) é considerada uma extensão da Análise de Correspondência Simples (CA), aplicada especificamente a tabelas que contêm indivíduos e suas respostas a variáveis categóricas.

A MCA utiliza os mesmos princípios matemáticos da CA.

Aplicada em dados que:

- As linhas representam indivíduos.
- As colunas representam variáveis categóricas.
- As células indicam a resposta do indivíduo.


Matriz de Burt

A Matriz de Burt é um tipo de matriz de contingência utilizada na Análise de Correspondência Múltipla (MCA).


É construída a partir de variáveis categóricas e contém todas as combinações possíveis entre categorias, organizadas de forma simétrica.

Considera conjuntamente a tabela de frequência de cada variável em sua diagonal e as tabelas de contingências 2x2 fora da diagonal e de forma simétrica.


Simple contingency table



Indicator matrix



Burt matrix



Pasaribu, U. S., Lestari, K. E., Indratno, S. W., Garminia, H., & Sari, R. K. N. (2021). Some properties of the scaled Burt matrix on multiple correspondence analysis. Journal of Hunan University Natural Sciences, 48(5).

Análise de Correspondência Múltipla

As distâncias entre indivíduos podem ser calculadas adicionando as diferenças entre categorias, $(x_{ik} - x_{i'k})^2$, e usando uma função inversamente proporcional a I_k (com I_k o número de indivíduos carregando a categoria k):

$$d_{i,i'}^2 = C \sum_{k=1}^K \frac{(x_{ik} - x_{i'k})^2}{I_k}$$

A distância entre duas categorias k e k' :

$$d_{k,k'}^2 = C' \sum_{k=1}^K \frac{I_{k \neq k'}}{I_k I_{k'}}$$

com C e C' constantes.

Análise de Correspondência Múltipla

A MCA é amplamente utilizada para:

- Identificar padrões nas respostas dos entrevistados.
- Explorar relações entre diferentes variáveis categóricas.
- Representar visualmente as relações entre categorias e indivíduos.
- Reduzir a complexidade dos dados e facilitar a interpretação.

Relação entre MCA e CA

Considere a distância entre dois indivíduos i e i' como:

$$\begin{aligned}d_{i,i'}^2 &= \frac{I}{J} \sum_{k=1}^K \frac{1}{I_k} (x_{ik} - x_{i'k})^2, \\&= \sum_{k=1}^K \frac{IJ}{I_k(IJ)} \left(\frac{x_{ik}}{J} - \frac{x_{i'k}}{J} \right)^2, \\&= \sum_{k=1}^K \frac{1}{I_k/(IJ)} \left(\frac{x_{ik}/(IJ)}{1/I} - \frac{x_{i'k}/(IJ)}{1/I} \right)^2.\end{aligned}$$

Ao incluir as notações da tabela de contingência introduzidas na CA e aplicadas à matriz indicadora, obtemos:

$$f_{ik} = x_{ik}/(IJ),$$

$$f_{i\bullet} = \sum_{k=1}^I x_{ik}/(IJ) = I_k/(IJ),$$

$$f_{\bullet k} = \sum_{i=1}^I x_{ik}/(IJ) = 1/I.$$

Podemos identificar a distância qui-quadrado entre os perfis de linha i e i' , calculada a partir da matriz indicadora:

$$d_{\chi^2}^2(\text{perfil de linha } i, \text{ perfil de linha } i') = \sum_{k=1}^K \frac{1}{f_{\bullet k}} \left(\frac{f_{ik}}{f_{i\bullet}} - \frac{f_{i'k}}{f_{i'\bullet}} \right)^2.$$

Além disso, se assumirmos que a constante $C' = I$, a distância (quadrada) entre duas categorias k e k' é expressa como:

$$\begin{aligned} d_{k,k'}^2 &= \frac{1}{I} \sum_{i=1}^I \frac{1}{I_k} (x_{ik} - x_{ik'})^2, \\ &= \sum_{i=1}^I \frac{1}{I} \frac{1}{I_k/(IJ)} \left(\frac{x_{ik}/(IJ)}{I_k/(IJ)} - \frac{x_{ik'}/(IJ)}{I'_k/(IJ)} \right)^2. \end{aligned}$$