

# APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 06

Redução de Dimensionalidade

# Redução de Dimensionalidade

Redução de Dimensionalidade pode ser definida como o processo de reduzir o número de covariáveis em um problema para obter apenas as principais variáveis.

Em outras palavras, se temos um dataset  $n \times p$  que  $p$  é a dimensão da covariável, a redução de dimensionalidade retornará um novo dataset onde de dimensão  $n \times k$  onde  $k < p$ .

Atualmente, são situações comuns onde as bases de dados de alta dimensão: imagens, textos, dados genéticos, etc.

# Redução de Dimensionalidade

A redução de dimensionalidade é um método exploratório que pode ser realizado com os seguintes fins:

- Visualização de dados;
- Pré-processamento dos dados antes da aplicação de outras técnicas;

# Análise de Componentes Principais

# Análise de Componentes Principais


É uma ferramenta tradicional da estatística multivariada.

- O PCA foi inventado em 1901 por Karl Pearson.

# Análise de Componentes Principais


- A análise de componentes principais (PCA) refere-se ao processo pelo qual os componentes principais são computados e o uso subsequente desses componentes na compreensão dos dados.
- As direções dos (novos) componentes são calculadas na direção em que as observações variam mais.

# Análise de Componentes Principais







# Análise de Componentes Principais




# Análise de Componentes Principais




# Análise de Componentes Principais




# Análise de Componentes Principais



# Análise de Componentes Principais



# Análise de Componentes Principais



# Análise de Componentes Principais

Uma componente principal (CP) é uma combinação linear das variáveis originalmente observadas,  $X_1, X_2, \dots, X_p$ , que explica o máximo possível da variabilidade dos dados.

A  $j$ -ésima CP,  $j = 1, \dots, p$ , assume a seguinte forma:

$$Z_j = a_{j1}X_1 + a_{j2}X_2 + \dots + a_{jp}X_p$$

em que:

$Z_j$  : é a  $j$ -ésima CP (os escores desta CP são dados por  $z_{ij}$ )

$a_{jk}$  : são as cargas da  $j$ -ésima CP

$X_k$  : é a  $k$ -ésima variável originalmente observada (em geral, padronizada)

# Análise de Componentes Principais

$$\begin{aligned} \max_{\mathbf{a}_1} f(\mathbf{a}_1) &= \text{var}(\mathbf{a}_1^T \mathbf{x}) = \mathbf{a}_1^T \mathbf{\Sigma} \mathbf{a}_1 \\ \text{sujeito a } g(\mathbf{a}_1) &= \mathbf{a}_1^T \mathbf{a}_1 = 1. \end{aligned}$$

$$\begin{aligned} \max_{\mathbf{a}_2} f(\mathbf{a}_2) &= \text{var}(\mathbf{a}_2^T \mathbf{x}) = \mathbf{a}_2^T \mathbf{\Sigma} \mathbf{a}_2 \\ \text{sujeito a } \mathbf{a}_2^T \mathbf{a}_2 &= 1 \text{ e } \text{cov}(\mathbf{a}_1^T \mathbf{x}, \mathbf{a}_2^T \mathbf{x}) = 0 \end{aligned}$$

Maximização dada pela autovalores de  $\mathbf{\Sigma}$ :  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p > 0$ .

As variâncias já estão ordenadas.



# Análise de Componentes Principais

A proporção da variabilidade (PV) dos dados que é bem explicada pela  $j$ -ésima CP é dada por:

$$\lambda_j / (\lambda_1 + \dots + \lambda_p)$$

em que:

$\lambda_j$ : é o  $j$ -ésimo autovalor da matriz de correlações

As cargas  $a_{j1}, \dots, a_{jp}$  da  $j$ -ésima CP nada mais são do que as coordenadas do autovetor referente a  $\lambda_j$ .

# Análise de Componentes Principais

A partir da PV e do número de variáveis que são bem explicadas pelas  $v$  primeiras CPs é que se determina o número ideal de dimensões para a análise.

Em geral, escolhe-se  $v$  tal que:

PV explicada pelas  $v$  primeiras CPs apr. 0,80 ou 0,90


As CPs são não-correlacionadas entre si e cada uma das CPs possui (em caso de padronização) média 0 e variância  $\lambda_j$ ,  $j = 1, \dots, p$ .

# Análise de Componentes Principais

Este gráfico ajuda a visualizar as componentes de maior impacto na explicação da variabilidade.

Neste exemplo, após a 3ª componente, pouca informação é acrescentada pelas demais componentes (elbow method).

Considerando o método de  $\lambda > 1$ , temos a redução para duas componentes.



# Análise de Componentes Principais

As CPs podem ser usadas em uma análise supervisionada, por ex. como variáveis preditoras em um modelo de regressão ou de classificação, no lugar do conjunto original (maior!) de variáveis preditoras.

## Software e Implementações

Em R:

- `prcomp [base]`
- `princomp`

Em Python:

- `sklearn.decomposition.PCA`