

APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 07

Escalonamento Multidimensional

Redução de dimensionalidade

Redução de dimensionalidade é qualquer processo que forneça um pequeno número de k variáveis que descrevam as relações entre objetos representados originalmente em p -variáveis, a partir de medidas tomadas desses objetos ($k \ll p$).

Esse processo também é chamado de ordenação dos dados.

Em muitas técnicas, as variáveis sintéticas, também denominadas eixos ou componentes, são combinações lineares das medidas originais, do tipo:

$$Y = a_1x_1 + a_2x_2 + a_3x_3 + \dots + a_px_p$$

O que é um embedding?

Um *embedding* é a transcrição de um vetor de alta dimensão para um espaço de baixa dimensão. Idealmente, um *embedding* captura algumas das semânticas da entrada, juntando entradas semanticamente semelhantes no espaço de embedding.

Estimar um embedding:

$$\mathcal{X} = \{x_1, x_2, \dots, x_n\} \rightarrow \mathcal{Y} = \{y_1, y_2, \dots, y_n\}$$

Que preserve o quanto possível a estrutura dos dados de alta dimensão para um mapeamento em baixa dimensão.

MOTIVAÇÃO

Quando os objetos de estudo são dados por proximidades, especialmente em casos onde as distâncias euclidianas não fazem sentido, PCA não é recomendada.

MDS CLÁSSICO

O MDS (*Multidimensional Scaling*), ou Escalonamento Multidimensional (EMD), muitas vezes é motivado pelo simples problema:

- Dadas apenas as distâncias entre os objetos, é possível construir um mapa exibindo suas distâncias relativas?

IDEIA

É suficiente conhecer apenas as distâncias entre os objetos no espaço original, sem a necessidade que as coordenadas de cada ponto sejam especificadas.

Tipos de MDS

Existem dois tipos de MDS:

- Escalonamento multidimensional Clássico: cMDS.
- Escalonamento multidimensional Métrico: mMDS.
- Escalonamento multidimensional não métrico: nMDS, MDS Ordinal.

O MDS Clássico (ou tradicional) também é conhecido como **Análise de Coordenadas Principais** - PCoA, ou Escalonamento Torgerson, ou Escalonamento Torgerson–Gower.

MDS techniques	Authors	Year
Foundation for MDS	Eckart and Young	1936-1938
Classical MDS (CMDS)	Torgerson	1952
Principal coordinate analysis	Gower	1966
Non-metric MDS (NMDS)	Shepard and Kruskal	1962-1964

Table II. Development of loss function for MDS

Loss functions	Authors	Year
Sammons non-linear mapping	Sammon	1969
Unfolding model	Coombs	1964
Individual differences models	Carroll and Chang	1970
ALSCAL	Takane	1977
Maximum likelihood based MDS	Ramsay	1982
MDS with optimal scaling	Meulman	1992-1993

Breve historia do MDS. SAEED, Nasir et al. A survey on multidimensional scaling. ACM Computing Surveys (CSUR), v. 51, n. 3, p. 1-25, 2018.

MDS e sua utilização

- O MDS cria um mapa de similaridade dos dados, sem operar diretamente na matriz de dados.
- É aplicado como matrizes de distâncias (matrizes de similaridade-dissimilaridade), que são derivadas da base original de dados.
- O MDS é usado principalmente para uma análise de dados geral, especialmente para visualização dados.
- **proximidade** é um termo utilizado para considerar ambos os termos similaridades-dissimilaridades.

PCA


O PCA está intimamente relacionado ao MDS. Na verdade, pode-se mostrar que o PCA é um caso especial de MDS clássico (PCoA) em cujas diferenças são distâncias euclidianas.

CRIME	Assassinato	Estupro	Roubo com agressão	Assalto a mão Armada	Roubo de Casas	Furto	Roubo de Carro
Assassinato	1,00	0,52	0,34	0,81	0,28	0,06	0,11
Estupro	0,52	1,00	0,55	0,70	0,68	0,60	0,44
Roubo com agressão	0,34	0,55	1,00	0,56	0,62	0,44	0,62
Assalto a mão Armada	0,81	0,70	0,56	1,00	0,52	0,32	0,33
Roubo de Casas	0,28	0,68	0,62	0,52	1,00	0,80	0,70
Furto	0,06	0,60	0,44	0,32	0,80	1,00	0,55
Roubo de Carro	0,11	0,44	0,62	0,33	0,70	0,55	1,00


Adaptado de BORG, Ingwer; GROENEN, Patrick JF; MAIR, Patrick. Applied multidimensional scaling. Springer Science and Business Media, 2012.

CRIME	Assassinato	Estupro	Roubo com agressão	Assalto a mão Armada	Roubo de Casas	Furto	Roubo de Carro
Assassinato	1,00	0,52	0,34	0,81	0,28	0,06	0,11
Estupro	0,52	1,00	0,55	0,70	0,68	0,60	0,44
Roubo com agressão	0,34	0,55	1,00	0,56	0,62	0,44	0,62
Assalto a mão Armada	0,81	0,70	0,56	1,00	0,52	0,32	0,33
Roubo de Casas	0,28	0,68	0,62	0,52	1,00	0,80	0,70
Furto	0,06	0,60	0,44	0,32	0,80	1,00	0,55
Roubo de Carro	0,11	0,44	0,62	0,33	0,70	0,55	1,00


Adaptado de BORG, Ingwer; GROENEN, Patrick JF; MAIR, Patrick. Applied multidimensional scaling. Springer Science and Business Media, 2012.




Adaptado de BORG, Ingwer; GROENEN, Patrick JF; MAIR, Patrick. Applied multidimensional scaling. Springer Science and Business Media, 2012.



Adaptado de BORG, Ingwer; GROENEN, Patrick JF; MAIR, Patrick. Applied multidimensional scaling. Springer Science and Business Media, 2012.



Adaptado de BORG, Ingwer; GROENEN, Patrick JF; MAIR, Patrick. Applied multidimensional scaling. Springer Science and Business Media, 2012.



Adaptado de BORG, Ingwer; GROENEN, Patrick JF; MAIR, Patrick. Applied multidimensional scaling. Springer Science and Business Media, 2012.

- Neste caso, os dados são devidamente visualizados para que se possa interpretar as distâncias como evidência empírica.
- Quanto mais próximos dois pontos no plano criado via MDS, maior a correlação das variáveis que os pontos representam.

Para n objetos de uma **matriz** de similaridade temos $m = n(n - 1)/2$ distâncias (ou dissimilaridades) entre pares de objetos.

- **Similaridade**: quanto maior o valor observado mais parecidos são os objetos. Ex.: o coeficiente de correlação linear.
- **Dissimilaridade**: quanto maior o valor observado menos parecidos (mais dissimilares) serão os objetos. Ex.: distâncias.

Distâncias e (Dis)similaridade

A similaridade (ou dissimilaridade, diferença) entre observações é geralmente baseada em uma medida da distância entre elas.

Distância euclidiana: é a medida de distância mais utilizada, sendo a distância euclidiana entre dois pontos $(x_{11}, \dots, x_{1p})$ e $(x_{21}, \dots, x_{2p})$, num espaço p -dimensional, definida por:



$$\sqrt{(x_{11} - x_{21})^2 + \dots + (x_{1p} - x_{2p})^2}$$

Distância Euclidiana (L2 norm)

$$d_{Eu}(x, y) = \sqrt{\sum_{i=1}^p (x_i - y_i)^2}$$

Distância de Manhattan (L1 norm)

$$d_{Ma}(x, y) = \sum_{i=1}^p |x_i - y_i|$$



Propriedades das distâncias:

- Positividade
 - $d(x, y) \geq 0$ para todo x e y .
 - $d(x, y) = 0$ se e somente se $x = y$,
- Simetria
 - $d(x, y) = d(y, x)$ para todo x e y
- Desigualdade triangular
 - $d(x, z) \leq d(x, y) + d(y, z)$ para todo x, y e z

Uma função de distância também é chamada de **métrica**.

Distância de Minkowski

$$d_{Mi}(x, y) = \left(\sum_{i=1}^p |x_i - y_i|^L \right)^{\frac{1}{L}}$$

Quando,


- $L = 1$: distância de Manhattan
- $L = 2$: distância de Euclidiana
- $L = \infty$: distância de Chebyshev ($L \infty$ norm)

Embora L possa ser qualquer valor real é normalmente utilizando entre 1 e 2. Para valores de L menores que 1, a d_{Mi} não define uma métrica de distância válida, pois a desigualdade triangular não é satisfeita.

Distância de Chebyshev (L_∞ norm)

$$d_{Ch}(x, y) = \max_i |x_i - y_i|$$

Qualquer ponto nas bordas, resulta no mesmo valor de distância do centro (amarelo)



Coeficiente de Jaccard

		Indivíduo i		
		1	0	Total
Indivíduo j	1	a	b	$a + b$
	0	c	d	$c + d$
	Total	$a + c$	$b + d$	$a + b + c + d$

Coeficiente de similaridade de Jaccard:

$$s_{i,j} = \frac{a}{a + b + c}$$

Note que $n = a + b + c + d$.

A distância de Jaccard é dada por $d_J(i, j) = 1 - s_{i,j}$.

Conversão de similaridades em dissimilaridades

Método	Conversão
Correlação	$\delta_{ij} = \sqrt{1 - r_{ij}}$
Reversa	$\delta_{ij} = \min(s_{ij}) + \max(s_{ij}) - s_{ij}$
Recíproca	$\delta_{ij} = 1/s_{ij}$
Filiação	$\delta_{ij} = 1 - s_{ij}$
Postos	$\delta_{ij} = \text{rank}(-s_{ij})$
Exponencial	$\delta_{ij} = -\log\left(\frac{s_{ij}}{\max(s_{ij})}\right)$
Gaussiana	$\delta_{ij} = \sqrt{-\log\left(\frac{s_{ij}}{\max(s_{ij})}\right)}$

similaridades s_{ij} , correlações r_{ij} , frequências f_{ij} , proporções/probabilidades p_{ij}

Conversão de similaridades em dissimilaridades

Método	Conversão
Transição	$\delta_{ij} = \frac{1}{f_{ij}}$
Co-concorrência	$\delta_{ij} = \left(1 + \frac{f_{ij} \sum_{i,j} f_{ij}}{\sum_i f_{ij} \sum_j f_{ij}} \right)^{-1}$
Gravidade	$\delta_{ij} = \sqrt{\frac{\sum_i f_{ij} \sum_j f_{ij}}{f_{ij} \sum_{i,j} f_{ij}}}$
Proporções de confusão	$\delta_{ij} = 1 - p_{ij}$
Probabilidades	$\delta_{ij} = \frac{1}{\sqrt{\arcsin(p_{ij})}}$
Valor inteiro z	$\delta_{ij} = z - s_{ij}$

similaridades s_{ij} , correlações r_{ij} , frequências f_{ij} , proporções/probabilidades p_{ij}

Visão Matricial

Seja $\mathbf{D} = \{d_{ij}\}$ a matriz de distâncias e $\mathbf{A} = \{a_{ij}\}$ a matriz composta pelos seguintes elementos:

$$a_{ij} = -\frac{1}{2} \left[d_{ij}^2 - d_{i\cdot}^2 - d_{\cdot j}^2 + d_{\cdot\cdot}^2 \right]$$

em que:

- $d_{i\cdot}^2 = n^{-1} \sum_j d_{ij}^2$
- $d_{\cdot j}^2 = n^{-1} \sum_i d_{ij}^2$
- $d_{\cdot\cdot}^2 = n^{-2} \sum_{i,j} d_{ij}^2$

Esta transformação preserva a relação de distâncias para todo i e j (Legendre e Legendre 1998, pág. 430).

$$\mathbf{A} = -\frac{1}{2} \left[\mathbf{I} - \frac{1}{n} \mathbf{1}\mathbf{1}' \right] \mathbf{D}^2 \left[\mathbf{I} - \frac{1}{n} \mathbf{1}\mathbf{1}' \right]$$

sendo $\mathbf{I}$ matriz identidade de ordem n e $\mathbf{1}_{n \times 1} = (1 \ 1 \ \dots \ 1)'$.

A matriz $\mathbf{A}$ tem dimensão $(n \times n)$ e é uma matriz **positiva definida**, então aplica-se a Decomposição Espectral:

$$\mathbf{A} = \mathbf{V}' \mathbf{\Lambda} \mathbf{V}$$

sendo $\mathbf{\Lambda}$ uma matriz diagonal com autovalores λ_i de $\mathbf{A}$.

Assim,

$$\mathbf{Y}_{n \times n} = \mathbf{V}_{n \times n} \mathbf{\Lambda}_{n \times n}^{1/2}$$

Redução de Dimensionalidade

A redução de dimensionalidade é realizada para $q \ll p$, de forma semelhante à PCA.

$$\mathbf{Y}_{n \times q} = \mathbf{V}_{n \times q} \mathbf{\Lambda}_{n \times q}^{1/2}$$

Quando a matriz de distâncias $\mathbf{D}$ é construída através da distância euclidiana, o MDS clássico resulta no PCA (Manly, 2008, pag. 183).

MDS Clássico e Métrico

Comumente o MDS clássico e o MDS métrico são tratados conjuntamente, pois possuem a mesma proposta.

Basicamente, o MDS clássico e o MDS métrico diferem apenas na abordagem de **estimação** que é utilizada.

O MDS métrico baseia-se na minimização de uma função de custo.

Função de custo

Encontrar novos pontos no novo espaço reduzido baseando-se nas distâncias pareadas de alta dimensão.

- δ_{ij} denota a medida dissimilaridade.
 - Não necessariamente euclidiana.
- $d_{ij} = \|\mathbf{y}_i - \mathbf{y}_j\|_2$,
 - Necessariamente euclidiana
 - Maior facilidade computacional

$$\mathcal{C} = \sum_{i < j} (\delta_{ij} - d_{ij})^2$$

PCA, cMDS, mMDS e nMDS

- A vantagem do MDS clássico (cMDS) e MDS métrico (mMDS) sobre o PCA é que qualquer medida de distância pode ser utilizada. Isso garante maior abrangência do método que pode ser aplicado a mais tipos de dados.
- O MDS clássico permite a obtenção do grau de explicação de cada eixo, pois é baseado em autovalores.
- Como o MDS é não linear, existe maior dificuldade de interpretação para novos eixos gerados.

PCA, cMDS, mMDS e nMDS

- O PCA é limitado aos coeficientes de correlação linear de Pearson e covariância, baseados em distância euclidiana.
- O nMDS também pode usar qualquer medida de proximidade, mas é melhor em preservar a estrutura de alta dimensão com alguns eixos.
- mMDS e nMDS não se baseiam em uma solução de autovalores, mas em métodos estimação via **otimização numérica**.
- Para conjuntos de dados grandes, os cálculos do nMDS e mMDS tendem a se tornar exaustivos.

cMDS e nMDS

A diferença entre mMDS e nMDS via otimização numérica é que no mMDS as distâncias do espaço reduzido devem corresponder às distâncias originais o mais próximo possível.

No NMDS, é a **ordem**, ou posto, das distâncias em **D** que tentamos representar o mais próximo possível.

Função Stress

Seja f uma função mónotona crescente

STRESS (STandardized Residual Sum of Squares) (Kruskal)

$$Stress_I = \frac{\sum_i \sum_j (f(\delta_{ij}) - d_{ij})^2}{\sum_i \sum_j d_{ij}^2}$$

SSTRESS ou STRESS\$_{II}\$

$$Stress_{II} = \frac{\sum_i \sum_j (f^2(\delta_{ij}) - d_{ij}^2)^2}{\sum_i \sum_j d_{ij}^4}$$


Geralmente, a minimização do STRESS é feita de forma interativa via Newton-Raphson.

Avaliação da Função Stress

STRESS	Avaliação
0.20	Ruim
0.10	Bom
0.00	Perfeito

Comumente o STRESS também é avaliado para o MDS métrico, quando f é igual a identidade.

Diagrama de Shepard



Alguns Comentários

- Dados de percepção, preferência, similaridade e dissimilaridade
- Possibilidade de interpretação das representações gráficas
- Possibilidade de verificação de qualidade da redução via métrica de STRESS
- Possibilidade de verificação de contribuição de cada o caso de autovalores
- Existem diferentes tipos de MDS

MDS, MCA e PCA

- A ACM pode ser vista como um caso especial de MDS, onde a medida de dissimilaridade usada é baseada na distância qui-quadrado em uma matriz de dados categóricos.
- A PCA pode ser visto como um caso especial do MDS clássico, quando a matriz de dissimilaridade é baseada em distância euclidiana dos próprios dados originais.

Software e Implementações

Em R:

- função nativa `cmdscale()` cMDS
- pacote `ecodist` função `pco` (cMDS ou PCoA)
- pacote `vegan` função `vegdist()` possui várias distâncias função `metaMDS()` nMDS
- pacote `smacof` vários tipos de MDS mMDS e nMDS

Software e Implementações

Em Python:

- `sklearn.manifold.MDS` mMDS e nMDS default='métrico' default='distância euclidiana'