

APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 08

Stochastic Neighbor Embedding

Métodos de redução de dimensionalidade

Os Métodos de redução de dimensionalidade podem ser:

- não-supervisionados / supervisionados
- linear / não-linear
- paramétricos / não-paramétricos


Métodos não-supervisionados, não-paramétricos e não-lineares.

MNIST Database


- 70 000 imagens
- 10 dígitos
- pixels 28×28 ($p = 784$)




Representação do Dataset MNIST




PCA com a identificação




PCA sem a identificação




Distribuição das distâncias simuladas para $p=2$




Distribuição das distâncias simuladas para $p=10$



Distribuição das distâncias simuladas para $p = 50$



Distribuição das distâncias simuladas para $p=500$




Distribuição das distâncias simuladas para $p= 2$

- Maldição de Dimensionalidade


IDEIA

Preservar os vizinhos mais próximos ao invés de preservar as distâncias.

- Stochastic neighbor embedding (SNE, 2002)
 - Hinton, G., & Roweis, S. T. (2002, December). Stochastic neighbor embedding. In NIPS (Vol. 15, pp. 833-840).
- t-distributed SNE (t-SNE, 2008) [+20 mil citações]
 - Van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. Journal of machine learning research, 9(11).




t-SNE



t-SNE sem identificação

Tensorflow playground



<https://projector.tensorflow.org/>

Artworks mapped using Machine Learning.



<https://experiments.withgoogle.com/t-sne-map>

Distribuição Normal Multivariada


Um vetor aleatório contínuo $\mathbf{X} = (X_1, \dots, X_p)$ segue distribuição normal multivariada com parâmetros $\boldsymbol{\mu} \in \mathbb{R}^p$ e $\boldsymbol{\Sigma}$, $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

sendo $\mathbf{X}$ o vetor de médias e $\boldsymbol{\Sigma}$ a matriz de variância e covariância.

Distribuição Normal Multivariada

Representação de $p = 2$.



Similaridade preservada

$$p_{i|j} = \frac{\exp\left\{-\delta_{ij}^2 / (2\sigma_i^2)\right\}}{\sum_{k, k \neq i} \exp\left\{-\delta_{ik}^2 / (2\sigma_i^2)\right\}}$$

- Onde σ_i^2 é a variância da Gaussiana centrada no ponto x_i .
- Em regiões mais densas, usualmente se usa um valor baixo para σ_i^2 , em regiões mais esparsas o valor de σ_i^2 normalmente é mais alto.
- σ_i é estimado através de um conjunto de dados fixo em **perplexidade** (número efetivo de vizinhos).
- $p_{ij} = (p_{i|j} + p_{j|i})/2$

$$q_{ij} = \frac{\exp\left\{-d_{ij}^2/2\right\}}{\sum_{k, k \neq i} \exp\left\{-d_{ik}^2/2\right\}}$$

Divergência de Kullback-Leibler

$$D_{\text{KL}}(P||Q) = - \sum_i P(i) \log \frac{Q(i)}{P(i)}$$


- $DKL(P||Q) \geq 0$
- $DKL(P||Q) = 0$ se e somente se $P = Q$
- Não é uma medida de distância, pois não é simétrica.
- Teoria da informação baseada na entropia de Shannon.

Encontrar um conjunto de baixa dimensão $\mathcal{Y} = \{y_1, y_2, \dots, y_n\}$ que minimize

$$\begin{aligned}\mathcal{C} &= \sum_i D_{\text{KL}}(P_i || Q_i) = \sum_i \sum_j p_{ij} \log \frac{p_{ij}}{q_{ij}} \\ &= \sum_i \sum_j p_{ij} \log p_{ij} - \sum_i \sum_j p_{ij} \log q_{ij}\end{aligned}$$

- altos valores de p_{ij} e baixos valores de $q_{ij} \rightarrow$ alta penalidade.
- baixos valores de p_{ij} e altos valores de $q_{ij} \rightarrow$ baixa penalidade.
- Método de estimação: Gradiente Descendente.

t-SNE



t-SNE

Kernel SNE:

- Kernel Gaussiano

$$k(d) = \exp\{-d^2\}$$

Kernel t -SNE:

- Kernel Cauchy
 - A distribuição de Cauchy padrão coincide com a distribuição t de Student com um grau de liberdade.

$$k(d) = \frac{1}{1 + d^2}$$

t-SNE

Agora,

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq i} (1 + \|y_i - y_k\|^2)^{-1}}$$

- Método de estimação gradiente descendente:


$$\frac{\partial \mathcal{C}}{\partial y_i} = 4 \sum_{j \neq i} (p_{ij} - q_{ij})(y_i - y_j)(1 + \|y_i - y_j\|^2)^{-1}$$

t-SNE

Incorporação de vizinhança estocástica da distribuição T, do inglês *t-distributed stochastic neighbor embedding (t-SNE)*.

- *força de repulsão* entre os pontos de dissimilaridades para as pequenas distâncias na representação de baixa dimensionalidade.
- A forte repulsão entre pontos de dados dissimilares, que são modeladas em pequenas distâncias, *não tendem ao infinito*.


t-SNE



Adaptado de <https://observablehq.com/@robert-browning/t-sne-t-distributed-stochastic-neighbor-embedding>

t-SNE

- Algoritmo de árvore Barnes-Hut
- Implementação para dados massivos



Alguns Comentários

- Um dos métodos em Estado da arte na pesquisa científica
- Extremamente útil para visualização (Manifolds)
- O algoritmo não preserva distâncias. É construído na tentativa de preservar a vizinhança.
- A função de custo não é convexa, então não há garantia de convergência para ótimo global.
- É importante que se use diversos reinícios ou até mesmo inicialização com outro algoritmo (PCA, por ex.)

Software e Implementações

Em R:

- pacote `tsne`
 - função `tsne()`
 - perplexidade 30
 - dados originais ou `dist`
- pacote `Rtsne`
 - Implementação Barnes-Hut
 - PCA como seed
 - perplexidade 30

Software e Implementações

Em Python:

- `sklearn.manifold.TSNE`
 - Implementação Barnes-Hut
 - perplexidade 30
 - métrica do espaço original é distância euclidiana