

APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 09

Introdução ao Kernel PCA

Por que Redução de Dimensionalidade?

Reduzir a dimensionalidade dos dados melhora a visualização, a eficiência de algoritmos e remove informações redundantes.

- Dados de alta dimensão são difíceis de visualizar e analisar com eficiência.
- Reduzir a dimensionalidade facilita o aprendizado de máquina e remove redundâncias.
- Técnicas como PCA permitem reduzir a complexidade mantendo a maior variância possível.

PCA

O Principal Component Analysis (PCA) busca representar os dados em um novo sistema de coordenadas com menos variáveis, retendo a maior variância possível.

- Técnica estatística usada para reduzir dimensões mantendo variância dos dados.
- Encontra os eixos principais ao longo dos quais os dados variam mais.
- Útil para compressão, visualização e pré-processamento.

Limitação do PCA Clássico

PCA clássico é limitado a dados linearmente separáveis, não sendo eficaz para padrões mais complexos.

- O PCA clássico só é eficaz quando os dados são linearmente separáveis.
- Ele não captura estruturas complexas ou relações não-lineares nos dados.
- Isso reduz sua aplicabilidade em tarefas com dados mais ricos.

Kernel PCA

Kernel PCA (Schölkopf, Smola & Muller, 1998) amplia o PCA para cenários não lineares usando funções kernel para projetar os dados em um espaço de maior dimensão.

- O Kernel PCA é uma extensão não-linear do PCA clássico.
- Transforma os dados para um espaço de alta dimensão usando uma função de kernel.
- Neste novo espaço, a separabilidade e a redução se tornam mais eficazes.

Mapeamento Não-Linear

A função de mapeamento $\phi(\mathbf{x})$ leva os dados para um novo espaço onde a separação linear pode ser aplicada.

- Usamos uma função $\phi(\mathbf{x})$ para mapear os dados para um espaço de características.
- No novo espaço, é possível aplicar PCA de forma mais eficaz.
- A função kernel $K(\mathbf{x}_i, \mathbf{x}_j)$ substitui a necessidade de calcular $\phi(\mathbf{x})$ diretamente.

Covariância com Kernel

A matriz de covariância é construída no espaço transformado, assumindo média zero para os dados mapeados.

- Assumimos que os dados no espaço transformado têm média zero.
- Calculamos a matriz de covariância usando $\phi(\mathbf{x}_i)\phi(\mathbf{x}_i)^T$.
- Isso forma a base para aplicar o PCA no novo espaço de características.

Autovetores de Kernel

Os autovetores no espaço kernel são combinações dos dados transformados e permitem a redução de dimensão.

- Os autovetores são expressos como combinações lineares das imagens $\phi(x_i)$.
- A equação principal é $K\alpha_k = \lambda_k n \alpha_k$, com K sendo a matriz de kernel.
- Esse problema de autovalor fornece os componentes principais no espaço transformado.

Projeção de Novos Dados

A projeção no espaço reduzido é feita usando os coeficientes α_k e a função kernel diretamente.

- Após calcular os autovetores, projetamos novos dados com:

$$\hat{x} = \sum_{i=1}^n \alpha_{ki} K(x, x_i)$$

- Isso permite utilizar a transformação sem computar diretamente $\phi(x)$.
- Assim, a redução de dimensionalidade é realizada de forma eficiente.

Centralização

Para o Kernel PCA funcionar corretamente, a matriz de kernel deve ser centralizada para média zero.

- O kernel precisa ser centralizado para que o PCA funcione corretamente.
- A centralização é feita com:

$$\hat{K} = K - \mathbf{1}K - K\mathbf{1} + \mathbf{1}K\mathbf{1}$$

sendo $\mathbf{1} = \frac{1}{n}\mathbf{1}\mathbf{1}^T$ garante a média nula no espaço do kernel.

Etapas Kernel PCA

O processo segue etapas semelhantes ao PCA, mas usando kernel e álgebra matricial sobre produtos internos.

1. Escolher o kernel apropriado para o problema.
1. Construir e centralizar a matriz de kernel K .
1. Resolver o problema de autovalor e projetar os dados com os componentes principais.

Exemplos de Kernels

A escolha do kernel define como as similaridades são medidas no novo espaço de características.

- Linear: $K(x_i, x_j) = x_i^T x_j$ — igual ao PCA clássico.
- Polinomial: $(x_i^T x_j + c)^d$ — permite capturar relações de ordem superior.
- RBF (gaussiano): $\exp(-\gamma \|x_i - x_j\|^2)$ — ideal para separações não-lineares suaves.

Mais Exemplos de Kernels

Outros kernels incluem funções ativação e medidas angulares de similaridade.

- Sigmoides: $\tanh(\gamma x_i^T x_j + c)$ — inspirado em redes neurais.
- Cosseno: $\frac{x_i^T x_j}{\|x_i\| \|x_j\|}$ — mede similaridade angular entre vetores.
- A escolha do kernel impacta fortemente a capacidade de separação no espaço reduzido.

Multi-Kernel PCA

Combinar múltiplos kernels permite capturar diferentes estruturas e padrões dos dados.

- Combinar múltiplos kernels pode capturar diferentes aspectos dos dados.
- Exemplo: $K_{\text{rbfpoly}} = K_{\text{rbf}}^T K_{\text{poly}}$ combina duas visões.
- Estratégia útil quando um único kernel não é suficiente.

Resultados: PCA vs Kernel PCA

No geral, o Kernel PCA é mais eficaz que o PCA clássico em dados não-lineares.

- Kernel PCA supera PCA clássico em dados como círculos e espirais.
- PCA linear funciona bem em dados como o conjunto Iris.
- A escolha do kernel afeta visivelmente o formato dos dados reduzidos.

Variância Explicada & Tempo

Kernel PCA explica mais variância, mas consome mais tempo de execução.

- Kernel PCA frequentemente explica mais variância com menos componentes.
- No entanto, tem maior custo computacional comparado ao PCA clássico.
- Há um equilíbrio entre performance e eficiência.

Quando Usar Kernel PCA?

Use Kernel PCA em problemas com não-linearidades, desde que o custo computacional seja aceitável.

- Use Kernel PCA quando os dados forem altamente não-lineares.
- Ideal para visualizações, clustering e pré-processamento não-linear.
- Evite quando tempo de processamento for uma limitação crítica.

Alguns comentários

Kernel PCA é uma poderosa ferramenta para redução não-linear de dados, especialmente em contextos complexos.

- Kernel PCA é uma técnica poderosa para redução de dimensionalidade não-linear.
- Combina flexibilidade dos kernels com os fundamentos do PCA.

Kernel PCA e MDS

O MDS clássico é um caso especial de Kernel PCA, quando o kernel é construído a partir da matriz de distâncias euclidianas.

- Kernel PCA: Maximizam a **variância** dos dados em um espaço transformado por kernel.
- MDS Clássico: Preserva ao máximo as **distâncias** entre pares de pontos ao reduzir a dimensão.
- MDS Clássico usa distâncias.
- Kernel PCA usa produtos internos: $K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$.

MDS como Caso Especial de Kernel PCA

- Se usarmos a matriz de distâncias (D^2) em MDS:

$$K = -\frac{1}{2}HD^2H$$

- Essa matriz (K) pode ser tratada como um kernel linear centrado.
- Portanto, MDS clássico = Kernel PCA com kernel baseado em distâncias.

Por Que Kernel PCA Não é MDS?

- Kernel PCA não depende de distâncias, mas de funções de kernel arbitrárias.
- Ele é mais geral: pode aplicar kernels como RBF, polinomial, sigmoid etc.
- Seu objetivo é maximizar variância