


APRENDIZADO NÃO SUPERVISIONADO

Bruno Melo e Prof. Anderson Ara

Slide 10

Análise de Agrupamento



Análise de Agrupamento

Os métodos de análise de agrupamento fornecem principalmente representações sintéticas dos objetos (na maioria das vezes, esses objetos são indivíduos, variáveis ou categorias de variáveis categóricas), correspondentes às linhas e colunas de uma tabela de dados.

Cluster

Por que o clustering é considerado aprendizagem não supervisionada, se ele também classifica objetos?

Supervisionado x Não Supervisionado

Supervisionado: A classificação supervisionada é comumente associada ao conceito de discriminação, onde o objetivo é prever uma variável categórica com base em variáveis independentes (ou preditoras).

Não Supervisionado: Envolve a organização de dados em grupos (clusters) sem a necessidade de rótulos de saída.

Cluster

A análise de agrupamento, também chamada de segmentação de dados, possui uma variedade de objetivos. Todos estão relacionados à tarefa de agrupar ou segmentar um conjunto de objetos em subconjuntos, ou “clusters”, de forma que os objetos dentro de cada grupo sejam mais semelhantes entre si do que em relação aos objetos de grupos diferentes.

Quando utilizar?

- Definir grupo / objetivos
- Exploração de dados
- Segmentação de clientes
- Agrupamento de documentos
- Pré-processamento para outras tarefas
- Segmentação de clientes

Método Hierarquico

Métodos hierárquicos de aglomeração começam com uma matriz de distâncias entre objetos. Todos os objetos começam sozinhos em grupos de tamanho um, e grupos que estão próximos se unem. Há várias maneiras de definir próximo. A mais simples é em termos de vizinhos mais próximos.

- Constrói uma hierarquia de agrupamentos, em forma de árvore (dendrograma).
- Não exige definir k de antemão

Método Particional

O clustering particional é uma abordagem de agrupamento que divide um conjunto de dados em k grupos distintos e não sobrepostos, de forma que cada ponto pertença exclusivamente a um único grupo, com base em uma medida de similaridade ou dissimilaridade.

- A ideia é minimizar a distância intra-grupo e maximizar a distância entre grupos.
- Precisa definir k previamente, sensível a outliers.

PCA x Clustering

Embora PCA também parta da ideia de medir relações entre variáveis (usando variância, covariância ou correlação), esses critérios estão embutidos no próprio algoritmo, sem exigir uma escolha explícita do usuário. Em outras palavras, a métrica de “proximidade” entre observações já é determinada implicitamente pelo cálculo dos autovalores e autovetores da matriz de covariância (ou correlação).

Por outro lado, no clustering, o usuário pode (e deve) escolher a medida de dissimilaridade (ou similaridade) mais apropriada ao contexto dos dados — como distância euclidiana, distância de Manhattan, coeficiente de Jaccard, entre outras.

Medidas de Proximidade

A análise de clustering pode utilizar medidas de proximidade, como similaridade ou dissimilaridade, para determinar como agrupar as observações. A ideia central é avaliar o quanto as observações são parecidas (ou diferentes) entre si para decidir a formação dos clusters.

Similaridade → Mede o quanto as observações são parecidas. Quanto mais alta a similaridade, mais as observações estão próximas e tendem a ser agrupadas no mesmo cluster.

Dissimilaridade → Mede o quanto as observações são diferentes. Quanto menor a dissimilaridade (maior a proximidade), mais as observações são consideradas para pertencer ao mesmo cluster.

Dissimilaridade Geral

Como a maioria dos algoritmos populares de clusterização recebe uma matriz de dissimilaridade como entrada, devemos primeiro construir as dissimilaridades pareadas entre as observações. No caso mais comum, definimos uma dissimilaridade $d_j(x_{ij}, x_{i'j})$ entre os valores do j -ésimo atributo.

$$D(x_i, x_{i'}) = \sum_{j=1}^p d_j(x_{ij}, x_{i'j})$$

Dissimilaridade Geral

A definição de dissimilaridade depende do tipo de variável. Para variáveis numéricas, usamos diferenças; para ordinais, respeitamos a ordem; para categóricas, comparamos com penalidades. Escolher a métrica certa é crucial para obter agrupamentos coerentes.

Dissimilaridade Geral

A escolha da medida de dissimilaridade correta, considerando os pesos dos atributos, é mais importante do que a escolha do algoritmo de clustering. Isso requer um bom entendimento do domínio do problema e não pode ser totalmente generalizado para todos os cenários.

Cluster

O objetivo da análise de clusters é dividir as observações em grupos ou "clusters", de maneira que as dissimilaridades entre as observações do mesmo cluster sejam menores do que entre as observações de clusters diferentes.

Cluster

Algoritmos de clustering populares normalmente atribuem cada observação a um único cluster, sem assumir um modelo probabilístico dos dados. A meta é encontrar uma atribuição ótima que *minimize a dissimilaridade dentro dos clusters e/ou maximize a separação entre clusters*.

Cluster

Objetivo do Clustering Particional

Dados:

- N observações, cada uma com ID único $i \in \{1, \dots, N\}$
- Matriz de dissimilaridades $d(x_i, x_{i'})$ pré-definida

Saída:

- Atribuição $C(i) = k$ de cada observação a um dos K clusters

Restrição: $K < N$ (número de clusters pré-definido)

Cluster

Qualidade da Partição

- Os indivíduos dentro de um mesmo cluster são homogêneos (baixa variabilidade intra-cluster).
- Os indivíduos diferem entre clusters distintos (alta variabilidade inter-cluster).

Cluster

Critério de Otimização

Minimizar a dispersão intra-cluster:

$$W(C) = \frac{1}{2} \sum_{k=1}^K \sum_{C(i)=k} \sum_{C(i')=k} d(x_i, x_{i'})$$

Relação Fundamental:

$$T = W(C) + B(C)$$

- T : Dispersão total (constante)
- $B(C)$: Dispersão inter-cluster

Cluster

Número de Partições Possíveis

Fórmula de Jain e Dubes (1988):

$$S(N, K) = \frac{1}{K!} \sum_{k=1}^K (-1)^{K-k} \binom{K}{k} k^N$$

Exemplos:

- $S(10, 4) = 34,105$ (factível)
- $S(19, 4) \approx 10^{10}$ (inviável)

Cluster

Algoritmos Iterativos de Descida

1. **Inicialização**: Partição aleatória ou heurística
2. **Iteração**:
 - Perturbação local das atribuições
 - Aceitação se $W(C)$ diminuir
3. **Terminação**: Ótimo local alcançado

Limitação:

- Exploram apenas uma fração infinitesimal do espaço de soluções
- Convergência para subótimos dependente da inicialização

Cluster

Soluções práticas

Algoritmos como o K-Means usam estratégias simples, mas eficazes, para encontrar boas soluções na prática. Em vez de buscar a solução perfeita (o que pode ser inviável), eles seguem um caminho mais pragmático:

- Começam com uma partição inicial aleatória dos dados — uma espécie de chute inicial.
- A cada passo, fazem ajustes incrementais que melhoram a função objetivo (como reduzir a soma das distâncias dentro dos grupos).
- O processo continua até que nenhuma melhora significativa seja possível — ou seja, o algoritmo converge.

Esse tipo de abordagem é chamada de gulosa, porque sempre tenta melhorar a solução localmente em cada iteração, mesmo sem garantir o melhor resultado global. Ainda assim, funciona muito bem na prática para muitos problemas do mundo real.

Cluster

Limitações

Apesar de sua simplicidade e eficiência, algoritmos como o K-Means têm algumas limitações importantes:

- Eles exploram apenas uma fração minúscula de todas as formas possíveis de agrupar os dados. Ou seja, deixam de considerar muitas outras partições que poderiam ser melhores.
- Como seguem uma estratégia gulosa, costumam convergir para ótimos locais, e não necessariamente para a melhor solução global.

Mesmo assim, esses métodos costumam funcionar surpreendentemente bem na prática, especialmente quando acompanhados de boas práticas como múltiplas inicializações.


Cluster

Tipos de Algoritmos de Clustering

Existem três tipos principais de algoritmos de clustering:

- Algoritmos Combinatórios
- Modelagem de Mistura (Mixture Modeling)
- Busca da Moda (Mode Seeking)

Cluster



Kmeans

Table: Linha do tempo do desenvolvimento do algoritmo K-means

Ano	Contribuição	Autores
1956	Ideia inicial de particionamento	Hugo Steinhaus
1957	Algoritmo iterativo (não publicado)	Stuart Lloyd
1967	Termo "K-means" e formalização	James MacQueen
1979	Otimização (evitando mínimos locais)	Hartigan & Wong
2007	Inicialização K-means++	Arthur & Vassilvitskii

Kmeans

Ele é projetado para situações em que:

- Clusterização particional
- Atribuição rígida (hard clustering)
- Minimização de variância intra-cluster

Kmeans

Formulação Matemática:

$$\min_C \sum_{k=1}^K \sum_{C(i)=k} \|x_i - \mu_k\|^2$$

onde:

- C : Atribuição de clusters
- μ_k : Centróide do cluster k
- x_i : Observação i -ésima

Kmeans

Teorema de Huygens

Decomposição da inércia total:

$$T = W(C) + B(C)$$

onde:

$$W(C) = \sum_{k=1}^K \sum_{C(i)=k} \|x_i - \mu_k\|^2 \quad (\text{Inércia intra-cluster})$$

$$B(C) = \sum_{k=1}^K n_k \|\mu_k - \bar{x}\|^2 \quad (\text{Inércia inter-clusters})$$

Kmeans

Implementação do Algoritmo

Passos Iterativos

- Inicialização:
Selecionar K centróides $\{\mu_1^{(0)}, \dots, \mu_K^{(0)}\}$

- Atribuição:

$$C^{(t)}(i) = \underset{1 \leq k \leq K}{\operatorname{argmin}} \|x_i - \mu_k^{(t)}\|^2$$

- Atualização:

$$\mu_k^{(t+1)} = \frac{1}{|C_k^{(t)}|} \sum_{C^{(t)}(i)=k} x_i$$

Kmeans

Implementação do Algoritmo

- Critério de Parada:

$$\|W^{(t+1)} - W^{(t)}\| < \epsilon$$

Kmeans

Análise de Convergência

Complexidade Computacional

Para N observações, K clusters e T iterações:

$$\mathcal{O}(N \cdot K \cdot T \cdot p)$$


onde p é o número de variáveis.

Kmeans

Como o algoritmo K-médias encontra um ótimo local ao invés de um ótimo global, então os resultados obtidos irão depender das atribuições (aleatórias) das observações aos K clusters iniciais.

Portanto, é importante rodar o algoritmo várias vezes, partindo de configurações iniciais (aleatórias) diferentes. E então, selecionar a melhor solução, isto é, aquela para a qual o valor da função-objetivo é menor.

Desvantagem: A escolha de K não é uma tarefa simples.



Kmeans

Exemplo 1

Primeiras linhas do dataset

cidade	uf	lat	lng
São Paulo	São Paulo	-23.5504	-46.6339
Rio de Janeiro	Rio de Janeiro	-22.9083	-43.1964
Belo Horizonte	Minas Gerais	-19.9281	-43.9419
Brasília	Distrito Federal	-15.7939	-47.8828
Salvador	Bahia	-12.9708	-38.5108
Fortaleza	Ceará	-3.7275	-38.5275

Kmeans


Selecionando as variáveis

```
#SELECIONANDO VARIÁVEIS
variaveis <- dados %>% select(lat, lng) %>%
  scale() %>% data.frame()

#APLICANDO K-MEANS
k <- 3
grupos <- variaveis %>% kmeans(k)
```


Kmeans

Plot dos Clusters para $k = 3$



Kmeans

Plot dos Clusters para $k = 3$



Kmeans

Método Elbow

O método Elbow é um dos métodos mais utilizados para determinar o número de clusters em um conjunto de dados.

Basicamente, consiste em analisar a variância explicada em função do número de clusters. Existem várias medidas de "variação explicada" usadas no método Elbow. Mais comumente, a variação é quantificada pela medida total de variação dentro dos clusters (total within-cluster variation) $W(C)$.

Kmeans

Método Elbow

Os primeiros clusters irão conter muitas observações e possivelmente alta variabilidade. Mas em algum ponto, a variação cairá drasticamente e gerará um ângulo no gráfico $K \times W(C)$.

O número de clusters 'K' é escolhido neste ponto, daí o "critério do cotovelo".

Kmeans


Método Elbow

O número ideal de clusters pode ser definido da seguinte forma:

- 1 - Algoritmo de agrupamento de cálculo (por exemplo, agrupamento de k-means) para diferentes valores de K . Por exemplo, variando K de 1 a 10 clusters.
- 2 - Para cada K , calcule o total within-cluster variation, $W(C)$.
- 3 - Trace a curva de $W(C)$ de acordo com o número de clusters K .
- 4 - A localização de uma dobra (cotovelo) no gráfico é geralmente considerada como um indicador do número apropriado de clusters.

Kmeans

Método Elbow



<https://www.oreilly.com/library/view/statistics-for-machine/9781788295758/c71ea970-0f3c-4973-8d3a-b09a7a6553c1.xhtml>

Kmeans

Exemplo

```
##      x y
## P1 1.0 1
## P2 1.5 2
## P3 5.0 5
## P4 6.0 6
```

Kmeans

Escolha inicial dos centróides

##		x	y	cluster
##	P1	1.0	1	1
##	P2	1.5	2	1
##	P3	5.0	5	2
##	P4	6.0	6	2


Kmeans

Recalcular os centróides

##	cluster	x	y
## 1	1	1.25	1.5
## 2	2	5.50	5.5

Kmeans

Gráfico



Nesta aula você viu:

Definição de agrupamento

Métodos de agrupamento Kmeans Método Elbow