

APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 11

Agrupamento Hierárquico

AGRUPAMENTO HIERÁRQUICO

O agrupamento hierárquico (hierarchical clustering) é um procedimento alternativo ao K-médias, sendo o agrupamento hierárquico aglomerativo (bottom-up ou agglomerative hierarchical clustering) o tipo mais comum.


Aglomerativo (AGNES - AGglomerative NESTing): Agrupa todas as observações em uma árvore com base na distância entre os pontos de dados.


Divisivo (DIANA - Divide ANALysis): Divide as observações em um número fixo de regiões com base na distância até os centros dos clusters.

AGRUPAMENTO HIERÁRQUICO

- Não requer a pré-especificação de K ;
- Resulta em uma representação muito útil e atraente das observações na forma de um diagrama de árvore (dendograma).
 - Um único dendograma pode ser usado para obter qualquer número de clusters.
 - Separe o dendograma em subárvores com base nos grupos.
 - Pode o dendrograma para obter o número necessário de grupos.

EXEMPLO DE DENDOGRAMA:





SOURCE: Ceriotti, M. (2019)

AGRUPAMENTO HIERÁRQUICO

Algoritmo

1. Considere cada uma das n observações como sendo seu próprio cluster (n clusters, a princípio). Calcule a distância (euclidiana, por ex.) entre cada par de clusters.
2. Selecione o par de clusters mais próximos e junte-os em um novo e único cluster.
3. Calcule a distância entre o novo cluster e cada um dos antigos clusters.
4. Repetir os passos 2 e 3 até que todas as observações estejam dentro de um único cluster.

AGRUPAMENTO HIERÁRQUICO

QUESTÃO:

Como definir a similaridade (ou a dissimilaridade/distância) entre dois clusters se cada um deles possui múltiplas observações?


SAÍDA:

Uso do conceito de **ligação** (linkage), que define a similaridade entre dois grupos de observações.


Tipos de ligação mais comuns (mais populares entre estatísticos): simples, completa e média.

TIPOS DE LIGAÇÃO


- Simple linkage



- Average linkage



- Complete linkage



TIPOS DE LIGAÇÃO

Ligação Simples (Single Linkage ou ligação por vizinho mais próximo): calcula a medida de similaridade (ex: distância euclidiana) entre as observações no cluster A e as observações no cluster B, e registra o menor valor desta medida.

TIPOS DE LIGAÇÃO

Ligação Completa (Complete Linkage ou ligação por vizinho mais distante): semelhante à anterior, mas registra o maior valor observado para a medida de similaridade.

TIPOS DE LIGAÇÃO

Ligação por Média (Average Linkage): semelhante às anteriores, mas registra o valor médio das medidas de similaridade.

Comentários

O dendograma resultante tipicamente depende muito fortemente do tipo de ligação usado (simples, completa, por média, por centróide, etc.), bem como da escolha da medida de similaridade (distância euclidiana, distância baseada em correlação, etc.).

Em geral, as ligações média e completa são preferíveis à ligação simples, visto que tendem a gerar dendogramas mais balanceados.

Variância intra cluster

Lembre-se: Seja $S \subset \mathbb{R}^d$ um conjunto de dados e $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$ uma partição de S .

A variância intra-cluster é definida por:

$$\text{WSS}(S, \mathcal{C}) = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

onde $\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$ é o **centroide** do cluster C_i .

- total within-cluster sum of square (WSS)
- total within-cluster variation

Ligação de Ward

Método de Ward (Método da mínima variância de Ward).

- agrupa os dois clusters que levam ao menor aumento no total dentro da variância do cluster.
- Intuitivamente, o método tenta reunir os dois clusters cujas médias são mais próximas.
- O método de Ward busca uma partição em que os clusters sejam o mais compactos e homogêneos possível.

Ligação de Ward

O método de Ward o $\Delta_{\text{Ward}}(C, C')$ como critério para decidir quais clusters devem ser fundidos. A cada passo do algoritmo hierárquico aglomerativo, ele escolhe os dois clusters C e C' que minimizam o seguinte termo:

$$\Delta_{\text{Ward}}(C, C') = \frac{|C| \cdot |C'|}{|C| + |C'|} \cdot |\mu - \mu'|^2$$

sendo:

- $|C|$ e $|C'|$ são os tamanhos dos clusters,
- μ e μ' são os centroides de C e C' , respectivamente,
- $\|\mu - \mu'\|^2$ é a distância euclidiana ao quadrado entre os centroides.

Ou seja, o método de Ward sempre escolhe agrupar os dois clusters cuja fusão resulta no menor aumento possível da função objetivo do k-means.

Ligação de Ward

Para quaisquer clusters $C, C' \subset \mathbb{R}^p$,

$$\text{WSS}(C \cup C') = \text{WSS}(C) + \text{WSS}(C') + \frac{|C| \cdot |C'|}{|C| + |C'|} \|\mu - \mu'\|^2$$

Ligação de Ward

Seja $\mu = \text{média}(C)$, $\mu' = \text{média}(C')$, e $\bar{\mu} = \text{média}(C \cup C')$.

$$\begin{aligned} \text{WSS}(C \cup C') - \text{WSS}(C) - \text{WSS}(C') &= \sum_{x \in C \cup C'} \|x - \bar{\mu}\|^2 - \sum_{x \in C} \|x - \mu\|^2 - \sum_{x \in C'} \|x - \mu'\|^2 \\ &= \sum_{x \in C} (\|x - \bar{\mu}\|^2 - \|x - \mu\|^2) + \sum_{x \in C'} (\|x - \bar{\mu}\|^2 - \|x - \mu'\|^2) \\ &= |C| \cdot \|\mu - \bar{\mu}\|^2 + |C'| \cdot \|\mu' - \bar{\mu}\|^2 \\ &= \frac{|C| \cdot |C'|}{|C| + |C'|} \|\mu - \mu'\|^2 \end{aligned}$$

Comentários

Muitas vezes, é importante padronizar as variáveis, de tal forma que elas tenham média zero e desvio-padrão unitário (antes do cálculo da medida de similaridade).

Em geral, métodos de agrupamento não são muito robustos à presença de perturbações (ruídos, outliers, remoção de observações) nos dados.

É possível, ainda, agrupar variáveis com base nas observações, a fim de descobrir subgrupos entre as variáveis.

A análise de cluster deve constituir um ponto de partida para o desenvolvimento de uma hipótese científica e estudo adicional, preferencialmente em um conjunto de dados independente.

Nesta aula você viu:

- ✓ Definição de agrupamento hierárquico
- ✓ Dendograma
- ✓ Tipos de ligação

