

# APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 12

# Introdução ao DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) é um algoritmo de agrupamento baseado na densidade que permite identificar regiões densas no espaço de atributos e agrupá-las, ignorando pontos considerados "ruídos".

Foi proposto por Martin Ester, Hans-Peter Kriegel, Jörg Sander e Xiaowei Xu em 1996 e é amplamente utilizado em aplicações de mineração de dados, reconhecimento de padrões e aprendizado não supervisionado.

Principais vantagens:

- Capaz de encontrar clusters de formas arbitrárias
- Não exige o número de clusters como entrada
- Lida bem com ruídos e outliers

# Por que não usar K-Means ou Agrupamento hierárquico?

Ambos:

- assumem que os clusters são convexos, esfericamente distribuídos.
- os clusters estão linearmente separados em termos da distância utilizada.
- sensíveis a outliers e ruídos;

O K-Means:

- Requer a definição prévia de "k"
- Sensível ao início dos centróides

O Agrupamento Hierárquico:

- têm densidade similar;
- definição do "k";
- diferentes tipos de ligação.


# Clustering por Densidade

Existem várias alternativas:




- Métodos baseados em densidade:
  - DBSCAN
  - OPTICS
  - DENCLUE

DBSCAN é uma das opções mais robustas e populares entre os métodos baseados em densidade.

# Clustering por Densidade



SOURCE: <https://medium.com/@fraidoonomarzai99/dbscan-in-depth-3fa4a8dbd3af>

**kmeans****CH.ward****DBSCAN**

# Clustering por Densidade

O clustering por densidade parte do princípio de que os clusters são áreas de maior densidade separadas por regiões de baixa densidade.

Esse tipo de abordagem permite identificar agrupamentos de forma arbitrária, detectando também os pontos que não pertencem a nenhum cluster (ruídos).

# Conceitos Fundamentais do DBSCAN

- Eps (  $\epsilon$  ): raio máximo da vizinhança
- MinPts: número mínimo de pontos em  $\epsilon$  para definir um núcleo

Estes dois parâmetros controlam como os agrupamentos são definidos.




# Tipos de Pontos no DBSCAN

- Ponto Núcleo (Core Point): possui pelo menos  $\text{MinPts}$  vizinhos dentro do raio  $\text{Eps}$ .
- Ponto Borda (Border Point): possui menos que  $\text{MinPts}$  vizinhos, mas está dentro da vizinhança de um ponto núcleo.
- Ponto Ruído (Noise Point): não é núcleo nem borda; é considerado ruído e não pertence a nenhum cluster.

Essas categorias ajudam o DBSCAN a distinguir estruturas densas de regiões esparsas.

# Tipos de Pontos no DBSCAN



# Acessibilidade por Densidade

Três conceitos fundamentais:

- **Diretamente acessível por densidade:** um ponto  $p$  está dentro da vizinhança  $Eps$  de um ponto núcleo  $q$ .
- **Acessível por densidade:** existe uma cadeia de pontos onde cada um é diretamente acessível por densidade a partir do anterior.
- **Conectado por densidade:** dois pontos  $p$  e  $q$  são conectados por densidade se houver um ponto  $o$  do qual ambos são acessíveis por densidade.

Estes conceitos permitem formar clusters de forma incremental.

# Eps e MinPts

- **Eps** ( $\epsilon$ ) define o raio máximo da vizinhança.
- **MinPts** define a quantidade mínima de pontos para que a região seja considerada densa.


## Como escolher **Eps**?

- A ideia é que, para pontos em um cluster, seus  $k$ -ésimos vizinhos mais próximos estejam aproximadamente à mesma distância.
- Pontos de ruído têm o  $k$ -ésimo vizinho mais próximo a uma distância maior.
- Portanto, plote a distância ordenada de cada ponto até seu  $k$ -ésimo vizinho mais próximo (por exemplo,  $k = 4$ ).
- Use o gráfico da distância do  $k$ -vizinho mais próximo ( $k = \text{MinPts} - 1$ ).
- O “joelho” do gráfico indica o melhor valor de **Eps**.

# Código R: Escolha de Eps com kNNdistplot

```
require(dbscan)
kNNdistplot(X, k = 4)
abline(h = 0.15, col = "red", lty = 2, lwd=2)
```

# Código R: Escolha de Eps com kNNdistplot



# Algoritmo DBSCAN (pseudo-código)

1. Marque todos os pontos como não visitados.
2. Para cada ponto  $p$ :
  - Se  $p$  for um ponto núcleo:
    - Crie um novo cluster.
    - Expanda esse cluster com todos os pontos acessíveis por densidade.
3. Pontos que não forem incluídos em nenhum cluster são considerados ruído.

Esse processo garante que regiões densas formem agrupamentos, enquanto pontos isolados são descartados.

# Código R para executar DBSCAN

```
library(dbSCAN)  
res <- dbSCAN(x, eps = 0.15, minPts = 4)
```

**x**: matriz de dados (ou data.frame)

**eps**: raio de vizinhança ( $\epsilon$ )

**minPts**: número mínimo de pontos para considerar um núcleo

O resultado **res\$cluster** contém os rótulos dos clusters, e 0 representa ruído.