

APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 13

Agrupamento baseado em mistura gaussiana

GMM - Gaussian Mixture Models

Modelos de mistura são comuns na modelagem estatística de uma ampla variedade de fenômenos.

Para os GMM (Gaussian Mixture Models), a premissa é que uma distribuição contínua pode ser aproximada por uma mistura finita de densidades gaussianas.

Os modelos de mistura gaussiana (GMMs) são considerados modelos semiparamétricos, pois não são definidos por uma única forma paramétrica nem se baseiam inteiramente nos dados.

O número de componentes utilizados no GMM pode variar, embora tenha uma forma simples para a função de densidade de probabilidade.

São geralmente estimados via algoritmo Expectation-Maximization (EM) (Dempster, Laird e Rubin, 1977), computacionalmente eficiente.

GMM - Gaussian Mixture Models

As GMMs podem ser utilizadas em diferentes tipos de tarefas de análise de dados:

- Modelagem de distribuições complexas: aproximação de dados multimodais.
- Imputação de dados: preenchimento de valores faltantes em dados multivariados.
- Detecção de anomalias: identificação de outliers via baixa probabilidade.
- **Clusterização: agrupamento probabilístico (soft clustering) de dados com formas e tamanhos variados.**


Hard Clustering vs. Soft Clustering

Hard clustering: Atribui cada ponto de dados a um único grupo, sem ambiguidade. O exemplo mais clássico é o algoritmo K-means, que divide os dados em regiões bem definidas com fronteiras rígidas. É simples e rápido, mas não lida bem com sobreposição entre grupos.

Soft clustering: Permite que cada ponto pertença a vários grupos com diferentes probabilidades. O exemplo mais comum é o Modelo de Mistura Gaussiana (GMM), que oferece uma abordagem probabilística e mais flexível, ideal quando os grupos não estão claramente separados.

- Intuição:
 - Hard: "Este ponto pertence ao cluster A."
 - Soft: "Este ponto tem 70% de chance de pertencer ao A, 30% ao B."

GMM - Gaussian Mixture Models



SOURCE: Ceriotti, M. (2019)

Distribuição Normal Univariada

Uma variável aleatória contínua X segue distribuição normal com $x \in \mathbb{R}$ e parâmetros $\mu \in \mathbb{R}$ e $\sigma^2 > 0$, $X \sim N(\mu, \sigma^2)$.

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x - \mu)^2}{2\sigma^2}\right\}$$

sendo os parâmetros μ e σ^2 , respectivamente, a esperança e a variância de X .

Distribuição Normal Multivariada

Um vetor aleatório contínuo $\mathbf{X} = (X_1, \dots, X_p)$ segue distribuição normal multivariada com parâmetros $\boldsymbol{\mu} \in \mathbb{R}^p$ e $\boldsymbol{\Sigma}$, $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}} |\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

sendo $\mathbf{X}$ o vetor de médias e $\boldsymbol{\Sigma}$ a matriz de variância e covariância.

Quando $\mathbf{X}$ tem uma distribuição normal multivariada, qualquer combinação linear de seus componentes $\sum_{j=1}^p a_j X_j$ tem uma distribuição normal univariada.

Distribuição Normal Multivariada

Seja $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$ uma amostra i.i.d. de uma normal multivariada $\mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

Estimativas de Máxima Verossimilhança

- Do vetor de médias:


$$\hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

- Da matriz de covariância:

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top$$

Distribuição Normal Multivariada

Representação de $p = 2$.




Misturas de Gaussianas

- Começamos com parâmetros que descrevem cada agrupamento
- Média μ_c , variância σ_c , "peso" π_c
- Distribuição de probabilidade:

$$p(x) = \sum_{c=1}^C \pi_c \mathcal{N}(x|\mu_c, \sigma_c)$$

com $0 < \pi_c < 1$ e $\sum_c \pi_c = 1$.

Misturas de Gaussianas



SOURCE: Oscar Contreras Carrasco

Forma com Variável Latente

- Forma equivalente com variável latente:

$$p(z = c) = \pi_c$$


$$p(x \mid z = c) = \mathcal{N}(x \mid \mu_c, \sigma_c)$$

Seleciona um componente da mistura com π

Amostra da Gaussiana desse componente

- **Atribuição latente z :**
 - Observamos x , mas z é oculto
 - $p(x)$ = marginal sobre x

Misturas de Gaussianas



Misturas de Gaussianas


Seja a mistura de duas gaussianas bivariadas,

$$p(\mathbf{x}) = \pi_1 \times \mathcal{N}_2(\mathbf{x}|\mu_1, \Sigma_1) + (1 - \pi_1) \times \mathcal{N}_2(\mathbf{x}|\mu_2, \Sigma_2)$$


Considere a primeira densidade com parâmetros $\mu_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ e $\Sigma_1 = \begin{pmatrix} 1 & 1/4 \\ 1/4 & 1 \end{pmatrix}$ e a segunda

$\mu_2 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}$ e $\Sigma_2 = \begin{pmatrix} 1 & 1/2 \\ 1/2 & 1 \end{pmatrix}$, sendo $\pi_1 = 0.6$.


Misturas de Gaussianas



Misturas de Gaussianas



Misturas de Gaussianas



SOURCE: Andrey Kan

Misturas de Gaussianas

Distribuição

Seja C o número finito de misturas, com $c = \{1, \dots, C\}$, a distribuição de mistura é dada por

$$p(\mathbf{x}|\Theta) = \sum_{c=1}^C \pi_c \mathcal{N}_p(\mathbf{x}|\mu_c, \Sigma_c)$$

com $\Theta = (\pi_1, \dots, \pi_{C-1}, \mu_1, \dots, \mu_C, \Sigma_1, \dots, \Sigma_C)$.

Misturas de Gaussianas

Estimação

A ideia é maximizar a verossimilhança conjunta dos dados:

$$L(\Theta) = \prod_{i=1}^n p(\mathbf{x}_i | \Theta)$$

A função de verossimilhança $L(\Theta) = p(\mathbf{x} | \Theta)$ pode ser escrita em forma logarítmica para facilitar a otimização:

$$\frac{\partial \log L(\Theta)}{\partial \Theta} = 0$$

Misturas de Gaussianas

Estimação

sendo, então:

$$\begin{aligned}\log L(\Theta) &= l(\Theta) \\ &= \log \prod_{i=1}^n p(\mathbf{x}_i | \Theta) \\ &= \sum_{i=1}^n \log \left(\sum_{c=1}^C \pi_c \mathcal{N}_p(\mathbf{x} | \mu_c, \Sigma_c) \right)\end{aligned}$$

Algoritmo EM

O algoritmo Expectation-Maximization (EM) (Dempster, Laird e Rubin, 1977) é uma poderosa técnica iterativa de otimização usada para estimar parâmetros em modelos estatísticos quando há dados ausentes ou contêm variáveis latentes (não observadas diretamente), como no caso do GMM.

É composto por duas etapas básicas:

E-step (Expectation):

- Calcula a esperança da log-verossimilhança completa, assumindo os parâmetros atuais.
 - Substitui variáveis ocultas por seus valores esperados.

M-step (Maximization):

- Maximiza essa esperança em relação aos parâmetros do modelo.
 - Atualiza os parâmetros com base nas estimativas da E-step.

Algoritmo EM

O algoritmo EM é amplamente usado para computar iterativamente estimativas de máxima verossimilhança (MLE) de distribuições, especialmente em modelos com variáveis ocultas ou dados incompletos.

É utilizado para estimar parâmetros Θ (pesos, médias e covariâncias) de um modelo de mistura (como GMMs), dado um conjunto de dados observado de dimensão p .

Estimativas no GMM via EM

Estimativas na etapa E

Na Etapa E, calculamos a **responsabilidade** de cada componente c pela observação $\mathbf{x}_i$:

$$\gamma_{ic} = p(z_i = c \mid \mathbf{x}_i) = \frac{\pi_c \cdot \mathcal{N}(\mathbf{x}_i \mid \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)}{\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_i \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}$$

- A responsabilidade γ_{ic} mede o quanto o componente c "explica" a observação $\mathbf{x}_i$.
- Cada observação recebe uma distribuição de probabilidades sobre os clusters.
- Essas responsabilidades serão usadas na próxima etapa para reestimar os parâmetros (Etapa M).
- A função densidade $\mathcal{N}(\mathbf{x}_i \mid \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$ é a densidade de uma normal multivariada.
- A Etapa E envolve apenas avaliação de densidades e normalização.

Estimativas no GMM via EM

Etapa E do Algoritmo EM

A Etapa E calcula a **esperança da log-verossimilhança completa**, com respeito à distribuição posterior dos rótulos ocultos z_i , dado os parâmetros atuais.

Cálculo das responsabilidades

$$\gamma_{ic} = \mathbb{E}[Z_{ic} \mid \mathbf{x}_i] = p(z_i = c \mid \mathbf{x}_i) = \frac{\pi_c \cdot \mathcal{N}(\mathbf{x}_i \mid \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)}{\sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mathbf{x}_i \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}$$

A Etapa E substitui variáveis ocultas por suas **esperanças condicionais**, preparando o terreno para a reestimativa dos parâmetros na Etapa M.

Estimativas no GMM via EM

Estimativas na etapa M

- Média do componente (c):

$$\hat{\boldsymbol{\mu}}_c = \frac{\sum_{i=1}^n \gamma_{ic} \mathbf{x}_i}{\sum_{i=1}^n \gamma_{ic}}$$

- Matriz de covariância:

$$\hat{\boldsymbol{\Sigma}}_c = \frac{\sum_{i=1}^n \gamma_{ic} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)^\top}{\sum_{i=1}^n \gamma_{ic}}$$

- Peso do componente:

$$\hat{\pi}_c = \frac{1}{n} \sum_{i=1}^n \gamma_{ic}$$

Estimativas no GMM via EM

A partir disso, o EM aplica um processo iterativo de 4 etapas para calcular Θ^* , os parâmetros que maximizam essa função, ou seu $\log L(\Theta)$.

Etapas do Algoritmo EM

1. Inicialize os parâmetros Θ^{old} . É comum usar centros otimizados do k-means como ponto de partida.
2. **E-step**: Calcule a esperança condicional para cada componente da mistura, dados os parâmetros atuais.
3. **M-step**: Atualiza os parâmetros Θ^{new} maximizando a verossimilhança, dados os valores esperados da E-step.
4. Verifique a convergência comparando a melhoria da verossimilhança (ou alguma outra métrica de informação) entre iterações sucessivas.

Estimativas no GMM via EM

Convergência e Observações

As etapas 2 a 4 são repetidas até que a função de verossimilhança se estabilize, indicando convergência para um ótimo local.

- A tolerância de convergência costuma ser 1×10^{-3} .
- Pode-se definir um número máximo de iterações (ex: 100).

Estimativas no GMM via EM

- As estimativas são ponderadas pelas responsabilidades.
- Refletem a incerteza sobre a associação das observações aos componentes.

O EM intera entre:

- E-step: calcular as responsabilidades γ_{ic}
- M-step: atualizar os parâmetros com base nas responsabilidades

Uma vez que o método é associado a **uma verossimilhança** é possível comparar facilmente a clusterização (soft) com pelo número de componentes.

Exemplo em R

```
require(mclust)

data("faithful")

clustgmm <- Mclust(faithful, G=2)

summary(clustgmm)

head(round(clustgmm$z,4))


plot(clustgmm, what = "classification")
plot(clustgmm, what = "density")
plot(clustgmm, what="uncertainty")
```


```


## -----
## Gaussian finite mixture model fitted by EM algorithm
## -----
##
## Mclust VVE (ellipsoidal, equal orientation) model with 2 components:
##
##   log-likelihood    n df          BIC          ICL
##   -1132.187  272  10  -2320.433  -2320.763
##
## Clustering table:
##    1    2
## 175  97


##      [,1]    [,2]
## 1 1.0000 0.0000
## 2 0.0000 1.0000
## 3 0.9999 0.0001
## 4 0.0000 1.0000
## 5 1.0000 0.0000
## 6 0.0022 0.9978

```









Critério de Informação Bayesiano (BIC)

O BIC é definido como:

$$\text{BIC} = -2 \cdot \log L + k \cdot \log(n)$$

onde:

- $\log L$: log-verossimilhança do modelo
- k : número de parâmetros
- n : número de observações

Note que:

- $-2 \log L$ verifica o ajuste
- $k \log(n)$ penaliza a complexidade

Número de Parâmetros da Mistura Gaussiana

Considere uma mistura finita de Gaussianas com:

- C : número de componentes (ou "clusters")
- p : dimensão dos dados (ou seja, normal $\mathcal{N}_p(\mu, \Sigma)$)

Total de parâmetros:

- Pesos: $k_\pi = C - 1$
- Médias: $k_\mu = C \cdot p$
- Covariâncias: $k_\Sigma = C \cdot \frac{p(p+1)}{2}$ (matrizes simétricas)

Total de Parâmetros: $k = k_\pi + k_\mu + k_\Sigma = C \cdot \frac{(p+1)(p+2)}{2} - 1$

Exemplo: Bivariado com $C = 2$

Se $C = 2$ e $p = 2$:

- Pesos: 1
- Médias: $2 \cdot 2 = 4$
- Covariâncias: $2 \cdot \frac{2(2+1)}{2} = 6$

Então, $k = 1 + 4 + 6 = 11$ parâmetros