

APRENDIZADO NÃO SUPERVISIONADO



Bruno Melo e Prof. Anderson Ara

Slide 14

Medidas de Validação

Short Review

- A análise de agrupamento, também chamada de segmentação de dados, possui uma variedade de objetivos. Todos estão relacionados à tarefa de agrupar ou segmentar um conjunto de objetos em subconjuntos, ou “clusters”, de forma que os objetos dentro de cada grupo sejam mais semelhantes entre si do que em relação aos objetos de grupos diferentes.
- O objetivo da análise de clusters é dividir as observações em grupos ou "clusters", de maneira que as dissimilaridades entre as observações do mesmo cluster sejam menores do que entre as observações de clusters diferentes.

Por que Avaliar a Qualidade de um Cluster?

A pergunta a ser respondida é se o modelo de grupos descoberto é, de fato, a organização em grupos dos dados sob análise. Porém, se não conhecemos a organização, como saber se o que descobrimos é o que deveríamos ter descoberto?

Por que Avaliar a Qualidade de um Cluster?

A clusterização, por ser uma técnica não supervisionada, não possui uma "resposta correta" pré-definida. Portanto, precisamos de métricas que nos ajudem a entender o quão bem os clusters formados representam a estrutura subjacente dos dados.

Com essas medidas, podemos:

- Comparar diferentes algoritmos de clusterização: Decidir qual algoritmo funciona melhor para um determinado conjunto de dados.
- Determinar o número ideal de clusters: Muitos algoritmos de clusterização exigem que o número de clusters seja especificado a priori. As medidas podem ajudar a encontrar o valor mais adequado.
- Avaliar a estabilidade dos clusters: Verificar se os agrupamentos são consistentes.

Estratégias

- Analisar a compacidade: encontramos grupos que maximizou a similaridade intragrupo?
- Analisar a separabilidade: encontramos grupos que minimizou a similaridade intergrupos?
- Analisar conhecimento a priori: usar informacoes que ja se tem sobre o conjunto de dados sob analise para validar os grupos encontrados.

Medidas de qualidade

As medidas de avaliação de agrupamentos, também conhecidas como critérios ou Índices, têm como objetivo avaliar a qualidade dos agrupamentos encontrados.

O objetivo da análise de clusters é dividir as observações em grupos ou "clusters", de maneira que as dissimilaridades entre as observações do mesmo cluster sejam menores do que entre as observações de clusters diferentes.

- Medidas externas: avaliam a estrutura encontrada comparando-as com uma conhecida a priori (informação externa);
- Medidas internas: avaliam a estrutura encontrada, com relação a algum critério, unicamente com informações dos próprios dados (informação interna).

Índices Externos

- Índice de Rand (Rand Index - RI)
- Índice de Jaccard
- Índice de Folkes e Mallows

Índice de Rand (Rand Index - RI)

O Índice de Rand mede a similaridade entre os clusters formados e os grupos reais (ou outra partição de referência), contando pares de pontos que estão na mesma categoria ou em categorias diferentes em ambas as partições.

Índice de Rand (Rand Index - RI)

Foto 1
Classe 1 | Cluster 1



Foto 2
Classe 1 | Cluster 1




Foto 3
Classe 2 | Cluster 2



Foto 4
Classe 2 | Cluster 1




Foto 5
Classe 2 | Cluster 2




Foto 6
Classe 1 | Cluster 2



Índice de Rand (Rand Index - RI)

Partição Real (Verdade Fundamental - GT):

- Gato: {F1,F2,F6}
- Cachorro: {F3,F4,F5}

Partição Obtida pelo Algoritmo de Clusterização (Alg):

- Grupo1: {F1,F2,F4}
- Grupo2: {F3,F5,F6}

Índice de Rand (Rand Index - RI)

Partição Real (Verdade Fundamental - GT):

Vamos analisar cada par de pontos possível e classificá-lo de acordo com as quatro categorias (a, b, c, d).

O número total de pares de pontos para N pontos é dado por:

$$\binom{N}{2} = \frac{N(N-1)}{2}$$

Para $N = 6$ pontos:

Índice de Rand (Rand Index - RI)

- $(F_1, F_2), (F_1, F_3), (F_1, F_4), (F_1, F_5), (F_1, F_6)$
- $(F_2, F_3), (F_2, F_4), (F_2, F_5), (F_2, F_6)$
- $(F_3, F_4), (F_3, F_5), (F_3, F_6)$
- $(F_4, F_5), (F_4, F_6)$
- (F_5, F_6)

Agora, vamos classificar cada um desses pares com base nas classes reais e nos clusters atribuídos pelo algoritmo.

Índice de Rand (Rand Index - RI)

Par	Mesmo GT?	Mesmo Cluster?	Cat
(F ₁ , F ₂)	Sim	Sim	a
(F ₁ , F ₃)	Não	Não	b
(F ₁ , F ₄)	Não	Sim	d
(F ₁ , F ₅)	Não	Não	b
(F ₁ , F ₆)	Sim	Não	c
(F ₂ , F ₃)	Não	Não	b
(F ₂ , F ₄)	Não	Sim	d
(F ₂ , F ₅)	Não	Não	b

Par	Mesmo GT?	Mesmo Cluster?	Cat
(F ₂ , F ₆)	Sim	Não	c
(F ₃ , F ₄)	Sim	Não	c
(F ₃ , F ₅)	Sim	Sim	a
(F ₃ , F ₆)	Não	Sim	d
(F ₄ , F ₅)	Sim	Não	c
(F ₄ , F ₆)	Não	Não	b
(F ₅ , F ₆)	Não	Sim	d

Índice de Rand (Rand Index - RI)

- **a** (Concordância Positiva):
 $(F_1, F_2), (F_3, F_5) \rightarrow 2$ pares
- **b** (Concordância Negativa):
 $(F_1, F_3), (F_1, F_5), (F_2, F_3), (F_2, F_5), (F_4, F_6) \rightarrow 5$ pares
- **c** (Falso Negativo):
 $(F_1, F_6), (F_2, F_6), (F_3, F_4), (F_4, F_5) \rightarrow 4$ pares
- **d** (Falso Positivo):
 $(F_1, F_4), (F_2, F_4), (F_3, F_6), (F_5, F_6) \rightarrow 4$ pares

Verificação: $a + b + c + d = 2 + 5 + 4 + 4 = 15$

Índice de Rand (Rand Index - RI)

A fórmula é:

$$RI = \frac{a + b}{a + b + c + d}$$

Índices Internos

- Within-cluster Sum of Squares (WSS)
- Índice de dunn
- Silhueta

Within-cluster Sum of Squares (WSS)

A medida Within-cluster Sum of Squares (WSS), ou Soma de Quadrados Dentro do Cluster, é uma das métricas mais utilizadas para avaliar a homogeneidade interna dos grupos formados por algoritmos de clusterização.

Ela é definida como:

$$\text{WSS} = \sum_{k=1}^K \sum_{\mathbf{x}_i \in G_k} \|\mathbf{x}_i - \mathbf{c}_k\|^2$$

- K : número de clusters
- G_k : conjunto de observações no cluster k
- $\mathbf{x}_i$: i -ésima observação
- $\mathbf{c}_k$: centróide do cluster k

Within-cluster Sum of Squares (WSS)

Interpretando:

- A WSS mede o quanto os pontos estão próximos do centróide do seu grupo.
- Quanto menor a WSS, mais compactos e homogêneos os clusters.

Para identificar o número ideal de grupos:

1. Calcula-se a WSS para diferentes valores de K .
2. Plota-se WSS em função de K (número de grupos).
3. Observa-se o "cotovelo" do gráfico: o ponto a partir do qual aumentar K não reduz significativamente a WSS.

Within-cluster Sum of Squares (WSS)

Short Review

O método Elbow é um dos métodos mais utilizados para determinar o número de clusters em um conjunto de dados.

Basicamente, consiste em analisar a variância explicada em função do número de clusters. Existem várias medidas de "variação explicada" usadas no método Elbow. Mais comumente, a variação é quantificada pela medida total de variação dentro dos clusters (total within-cluster variation) $W(C)$.

Within-cluster Sum of Squares (WSS)

Short Review

Os primeiros clusters irão conter muitas observações e possivelmente alta variabilidade. Mas em algum ponto, a variação cairá drasticamente e gerará um ângulo no gráfico $K \times W(C)$.

O número de clusters 'K' é escolhido neste ponto, daí o "critério do cotovelo".

Within-cluster Sum of Squares (WSS)


Short Review

O número ideal de clusters pode ser definido da seguinte forma:

- 1 - Algoritmo de agrupamento de cálculo (por exemplo, agrupamento de k-means) para diferentes valores de K . Por exemplo, variando K de 1 a 10 clusters.
- 2 - Para cada K , calcule o total within-cluster variation, $W(C)$.
- 3 - Trace a curva de $W(C)$ de acordo com o número de clusters K .
- 4 - A localização de uma dobra (cotovelo) no gráfico é geralmente considerada como um indicador do número apropriado de clusters.

Within-cluster Sum of Squares (WSS)

Short Review



<https://www.oreilly.com/library/view/statistics-for-machine/9781788295758/c71ea970-0f3c-4973-8d3a-b09a7a6553c1.xhtml>

Índice de Dunn (DU)

O índice de Dunn (DI) (introduzido por J. C. Dunn em 1974), uma métrica para avaliar algoritmos de agrupamento, é um esquema de avaliação interna, onde o resultado é baseado nos próprios dados agrupados. Como todos os outros índices, o objetivo deste índice de Dunn é identificar conjuntos de clusters compactos, com uma pequena variância entre os membros do cluster, e bem separados, onde as médias de diferentes clusters estão suficientemente distantes, em comparação com a variância dentro do cluster.

Quanto maior o valor do índice de Dunn, melhor é o agrupamento. O número de clusters que maximiza o índice de Dunn é considerado como o número ideal de clusters k . Ele também tem algumas desvantagens. À medida que o número de clusters e a dimensionalidade dos dados aumentam, o custo computacional também aumenta.

Índice de Dunn (DU)

O Índice de Dunn (DU) busca:

- Maximizar a distância intergrupos (entre clusters)
- Minimizar a distância intragrupos (dentro de cada cluster)

Índice de Dunn (DU)

$$DU = \min_{k1=1,\dots,K} \left[\min_{k2=1,\dots,K, k1 \neq k2} \left(\frac{d(G_{k1}, G_{k2})}{\max_{k3=1,\dots,K} \text{diam}(G_{k3})} \right) \right]$$

onde:

- $d(G_{k_1}, G_{k_2}) = \min_{\mathbf{x}_i \in G_{k_1}, \mathbf{x}_m \in G_{k_2}} d(\mathbf{x}_i, \mathbf{x}_m)$ é a menor distância entre os grupos G_{k_1} e G_{k_2} .
- $\text{diam}(G_{k_3}) = \max_{\mathbf{x}_i, \mathbf{x}_m \in G_{k_3}} d(\mathbf{x}_i, \mathbf{x}_m)$ é o diâmetro do grupo G_{k_3} .

Índice de Dunn (DU)

Interpretação

- O índice avalia o quão **separados** e **compactos** estão os clusters.
- Valores **maiores** indicam clusters mais bem definidos.

Aplicação

- Calcula-se DU para vários valores de K (número de clusters).
- Plota-se o índice versus K .
- Diferente do WSS, não é esperado um padrão "cotovelo".
- Um valor alto de DU pode indicar a quantidade ideal de clusters.

Índice de Dunn (DU)

Considere os seguintes 6 pontos em 2D, divididos em dois grupos:

- Grupo 1: A(1,1), B(2,1), C(2,2)
- Grupo 2: D(8,8), E(9,8), F(9,9)

Vamos calcular o **Dunn Index (DU)**, que busca:

- Maximizar a separação entre os grupos
- Minimizar a dispersão interna

Índice de Dunn (DU)

Comparando pontos entre Grupo 1 e Grupo 2:

- A-D: $\sqrt{(1-8)^2 + (1-8)^2} = \sqrt{98} \approx 9.899$
- B-D: $\sqrt{(2-8)^2 + (1-8)^2} = \sqrt{85} \approx 9.220$
- C-D: $\sqrt{(2-8)^2 + (2-8)^2} = \sqrt{72} \approx 8.485$

Menor distância intergrupos: 8.485

Índice de Dunn (DU)

Cálculo: Diâmetro Intragrupo

Grupo 1:

- $A-B = 1$
- $A-C = \sqrt{2} \approx 1.414$
- $B-C = 1$

Máximo: 1.414

Grupo 2:

- $D-E = 1$
- $D-F = \sqrt{2} \approx 1.414$
- $E-F = 1$

Máximo: 1.414

Maior diâmetro intragrupo: 1.414

Índice de Dunn (DU)

$$DU = \frac{8.485}{1.414} \approx 6.0$$

Índice de Dunn (DU)

Cálculo no R

```
# Distância Euclidiana
dist_euclid <- function(a, b) {
  sqrt(sum((a - b)^2))
}

# Diâmetro do cluster: maior distância entre pares de pontos no mesmo cluster
diametro_cluster <- function(grupo) {
  dists <- dist(grupo)
  max(dists)
}
```


Índice de Dunn (DU)

Cálculo no R

```
# Distância mínima intercluster
distancia_interclusters <- function(g1, g2) {
  min_dist <- Inf
  for (i in 1:nrow(g1)) {
    for (j in 1:nrow(g2)) {
      d <- dist_euclid(g1[i,], g2[j,])
      if (d < min_dist) min_dist <- d
    }
  }
  min_dist
}
```

Índice de Dunn (DU)

Cálculo no R

```
## Diâmetro Grupo 1: 1.414
```

```
## Diâmetro Grupo 2: 1.414
```

```
## Distância mínima interclusters: 8.485
```

```
## Índice de Dunn: 6
```

Índice de Dunn (DU)

```
require(clValid)
data(mouse)
express <- mouse[1:25,c("M1","M2","M3","NC1","NC2","NC3")]
rownames(express) <- mouse$ID[1:25]
DD <- dist(express)
clust <- hclust(DD, method="ward.D2")
nc <- 2
cluster <- cutree(clust,nc)
dunn(DD, cluster)
```

```
## [1] 0.4217497
```

Índice de Silhueta (Silhouette Index)

O índice de silhueta (sil), proposto por *Rousseeuw (1987)*, é um dos métodos mais populares para avaliar a qualidade de uma partição em clusters e estimar o número ideal de grupos.

Índice de Silhueta (Silhouette Index)

Para cada observação i , calcula-se:

$$\text{sil}(i) = \frac{b(i) - a(i)}{\max[a(i), b(i)]}$$

- $a(i)$: distância média da observação i para os demais pontos do mesmo grupo.
- $b(i)$: distância mínima da observação i para os pontos de outro grupo, ou seja, o grupo mais próximo diferente do seu.

Índice de Silhueta (Silhouette Index)

Interpretando:

- A silhueta geral é a média de $\text{sil}(i)$ para todas as observações.
- O valor de $\text{sil}(i)$ varia no intervalo $[-1, 1]$:
 - Próximo de 1: observação bem ajustada ao seu grupo.
 - Próximo de 0: observação na fronteira entre dois grupos.
 - Negativo: observação pode estar mal alocada (mais próxima de outro grupo).

Índice de Silhueta (Silhouette Index)

Definindo o k :

- Avalia-se o valor médio do índice para diferentes valores de K .
- O número ideal de grupos é aquele com maior valor médio de silhueta.

O índice de silhueta combina informação de **coesão intra-cluster** e **separação inter-cluster**, sendo uma medida robusta e interpretável para avaliação de agrupamentos.

Índice de Silhueta (Silhouette Index)

Exemplo

Temos os seguintes pontos:

- Grupo A: $x_1 = 1$, $x_2 = 2$
- Grupo B: $x_3 = 5$, $x_4 = 6$

Índice de Silhueta (Silhouette Index)

Exemplo

```
# Pontos
x <- c(1, 2, 5, 6)
names(x) <- paste0("x", 1:4)

# Matriz de distância
dist_matrix <- as.matrix(dist(x))
dist_matrix
```

```
##      x1 x2 x3 x4
## x1   0  1  4  5
## x2   1  0  3  4
## x3   4  3  0  1
## x4   5  4  1  0
```

Índice de Silhueta (Silhouette Index)

Exemplo

##	Ponto	a_i	b_i	Silhueta
## 1	x1	1	4.5	0.778
## 2	x2	1	3.5	0.714
## 3	x3	1	3.5	0.714
## 4	x4	1	4.5	0.778

Índice de Silhueta (Silhouette Index)

Exemplo


```
mean(sil_df$Silhueta)
```

```
## [1] 0.746
```

Índice de Silhueta (Silhouette Index)

```
require("cluster")
data("faithful")
DD <- dist(faithful)
clust <- hclust(DD, method="ward.D2")
cluster <- cutree(clust,k=2)
SI <- silhouette(cluster,DD)
plot(SI, cex.names = 0.5)
```

Índice de Silhueta (Silhouette Index)



Referências Bibliográficas

- Lima, C.A.M. & Peres, S.M. Medidas de avaliação de agrupamentos (Clustering), 2015. Disponível em: https://each.uspnet.usp.br/sarajane/wp-content/uploads/2015/11/avaliacao_clustering.pdf. Acesso em: 7 jun. 2025.
- Bruce, P. , Bruce, A. & Gedeck, P. Estatística para Ciência de Dados: Um livro prático com exemplos em Python e R.
- Fávero, L.P. & Belfiore, P. Manual de Análise de Dados - Estatística e Modelagem Multivariada com Excel®, SPSS® e Stata
- Hastie, T., Tibshirani, R. & FriedmanJerome (2008).
The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.). Springer.
- Izbicki, Rafael & Santos,Tiago Mendonça dos (2020).
Aprendizado de máquina: uma abordagem estatística